МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

KOICA
Korea International Cooperation Agency

Машин сургалт

Лекц № 7

Компьютерын ухааны салбар

This e-learning content was developed by the support of KOICA



Дэд профессор, док (PhD), Д.Золзаяа /email: zolzaya@must.edu.mn/
Компьютерын ухааны салбар

Хичээлийн агуулга

- Хичээлийн зорилго, ач холбогдол
- Машин сургалт гэж юу вэ?
- Машин сургалтын түүх, хэрэглээ
- Өгөгдөл
- Машин сургалтын алгоритмын төрлүүд
- Машин сургалтын Yesмоделийн үнэлгээ
- Дүгнэлт



Хичээлийн зорилго, ач холбогдол

- Энэ хичээлийн зорилго нь оюутнууд машин сургалтын үндсэн онол, аргууд, алгоритмуудтай танилцажуж, тэдгээрийг хэрэгжүүлэх чадварыг эзэмшихэд оршиж байна.
- Ач холбогдол
  - Технологийн дэвшил
  - Өгөгдөлд үндэслэсэн шийдвэр гаргалт
  - Инноваци ба шинэ бүтээл
  - Ажлын байрны боломжууд
  - Оночвлол, автоматжуулалт



Машин сургалт гэж юу вэ?

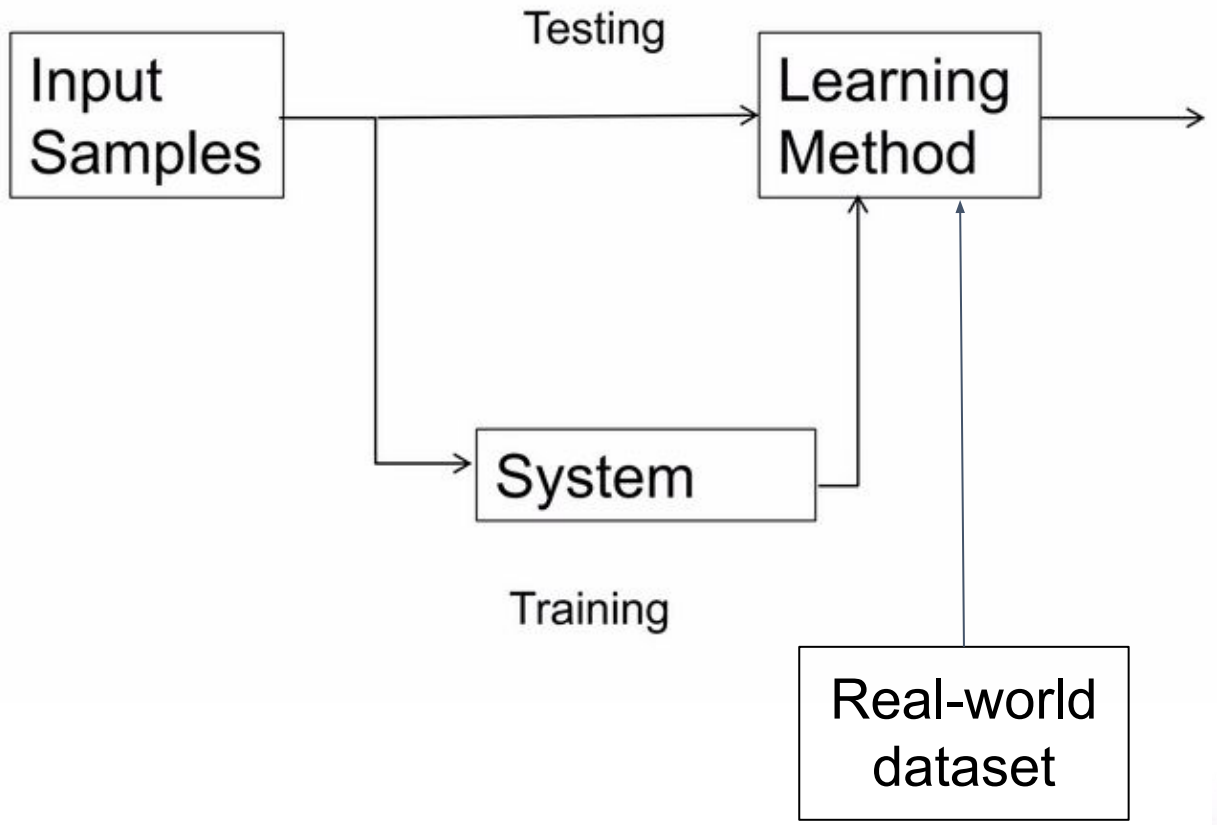
- Машин сургалт (Machine Learning) нь хиймэл оюун ухааны салбар бөгөөд өгөгдлөөс суралцаж, шинэ шийдлүүдийг боловсруулдаг компьютеруудын процессыг хэлнэ.
- Энэ нь програм хангамжийг тодорхой алгоритмуудыг ашиглан өөрийн туршлагаас суралцахад чиглэсэн байдаг.
- Машин сургалт нь тодорхой дүрмийг программчлахгүйгээр өгөгдлөөс паттерн (дүрэм) буюу хамаарлын шинж чанарыг олж, үүний дагуу шийдвэр гаргах чадвартай болгодог.



Машин сургалт гэж юу вэ?



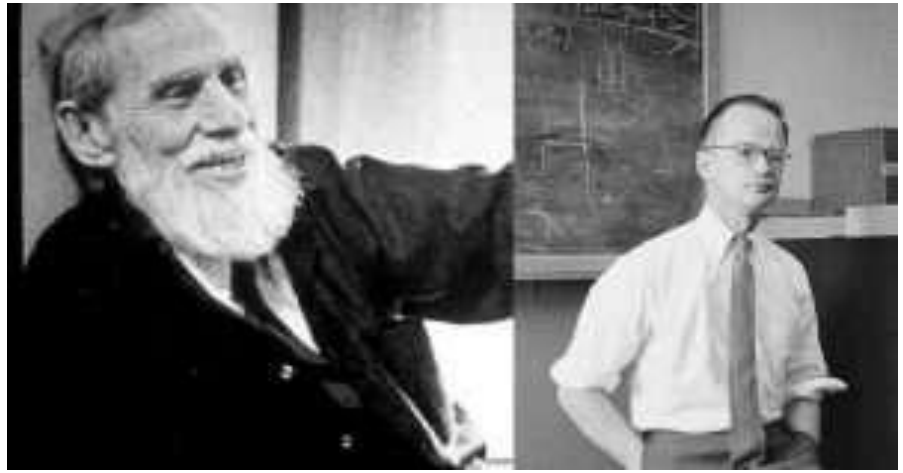


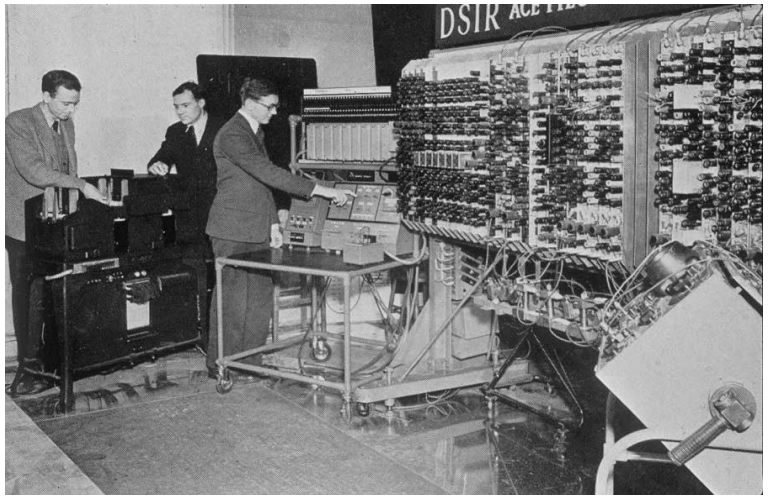




Машин сургалтын түүх, хэрэглээ

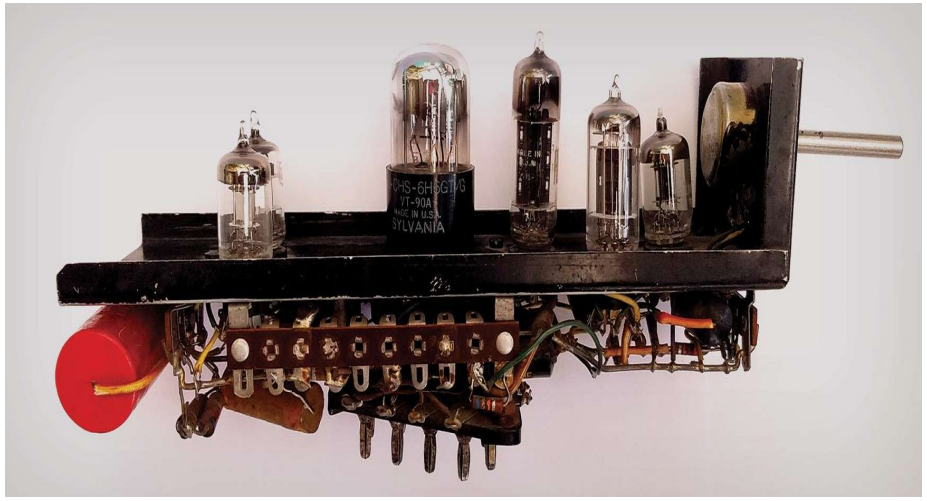
- Анхны үе (1940-1960-ад он)
  - Мэдрэлийн физиологич Уоррен Стургис МакКаллоч, логикч Уолтер Харри Питтс нар нейрон сүлжээний анхны математик загварыг гаргасан.
  - Алан Тьюринг (Alan Turing): Машин сургалтын суурийг тавьсан хамгийн анхны эрдэмтдийн нэг юм. Түүний Тьюрингийн туршилт нь машинууд болон хүний сэтгэн бодох чадварыг ялгахад зориулагдсан. Түүний ажлын үр дүнд хиймэл оюун ухааны үндсүүд тавигдсан.

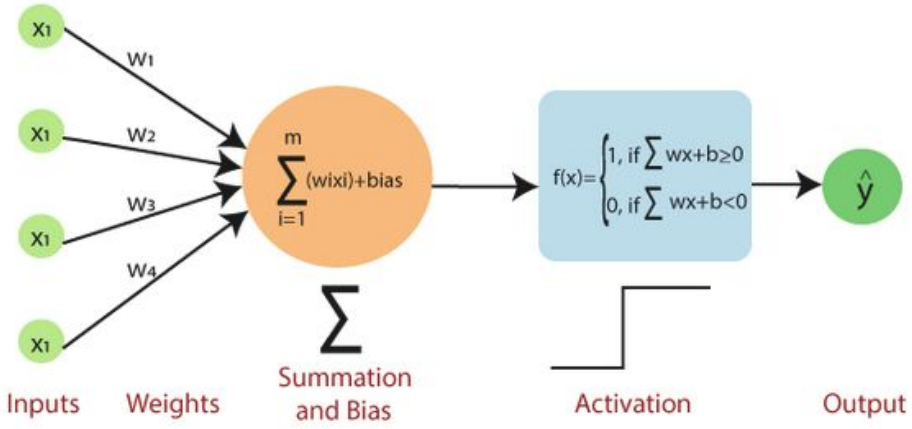






Машин сургалтын түүх, хэрэглээ



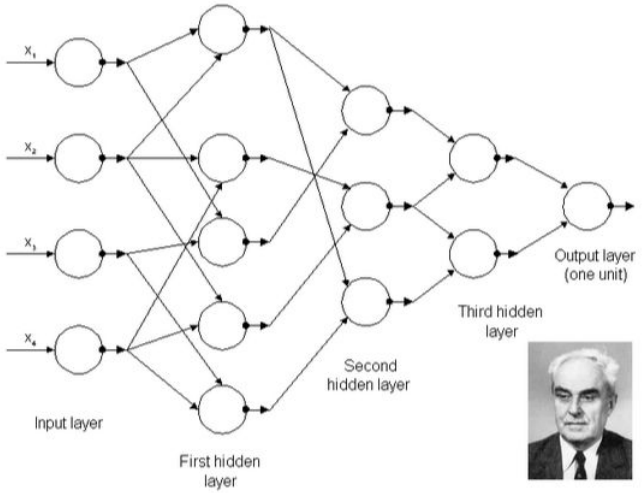


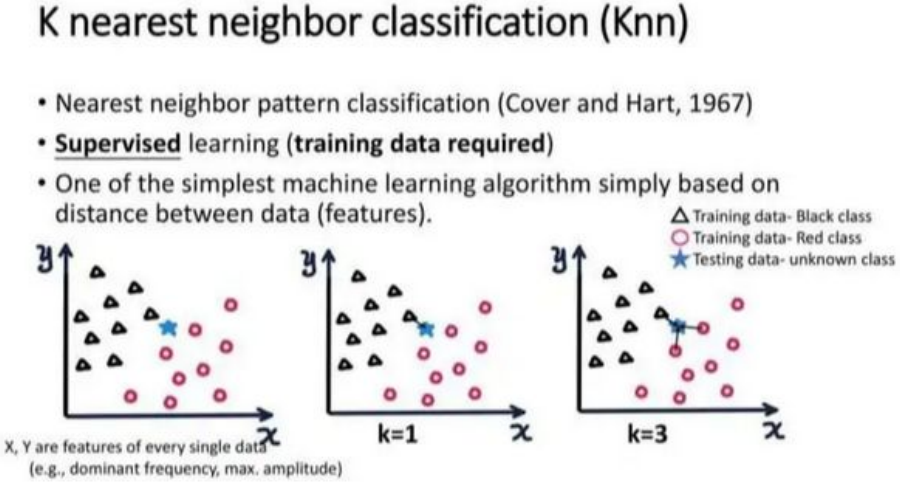
- Анхны үе (1940-1960-ад он)
  - 1951 онд компьютерын эрдэмтэн Марвин Мински, Дин Эдмондс нар анхны хиймэл мэдрэлийн сүлжээг бүтээсэн. Нейрон сүлжээ нь богино болон урт хугацааны санах ойтой, хоорондоо холбогдсон 40 мэдрэлийн эсээс бүрддэг.
  - Персептрон: 1957 онд, Фрэнк Розенблатт (Frank Rosenblatt) нь персептроны нэртэй алгоритм зохион бүтээсэн. Энэ нь өнөөгийн нейрон сүлжээний эхлэл болсон.



Машин сургалтын түүх, хэрэглээ

- Алгоритмуудын хөгжүүлэлт (1960-1980-аад он)
  - Нейрон сүлжээ: 1960-1970-аад онд, нейрон сүлжээний суурь зарчмуудыг боловсруулсан бөгөөд энэ нь хиймэл нейрон сүлжээний эхлэл болсон. Гэвч 1970-1980-аад онд, тооцооллын хүчин чадал бага байсан тул нейрон сүлжээний судалгаа хангалттай дэмжлэг авч чадаагүй.
  - Шийдвэрийн мод (Decision Trees) болон K- ойр байрлал (K-Nearest Neighbors, KNN): Энэ үед эдгээр алгоритмууд бий болсон бөгөөд эдгээр нь хожим нь ихээхэн ашиглагдаж эхэлсэн.







Машин сургалтын түүх, хэрэглээ

- Машин сургалтын хямрал ба шинэчлэл (1970-1990 он)
  - 1969: Марвин Минский, Сеймур Пейперт нар Perceptrons номондоо нэг давхарга бүхий perceptron нь XOR зэрэг төвөгтэй логикийг шийдэж чадахгүйг баталснаар мэдрэлийн сүлжээний судалгаа саарсан.
  - 1986: Жеффри Хинтон, Дэвид Румельхарт, Рональд Уильямс нар Backpropagation алгоритмыг хөгжүүлснээр олон давхаргат мэдрэлийн сүлжээ (MLP) дахин хөгжиж эхлэв.



MYCIN

Эмнэлгийн эксперт систем, цусны халдварын оношилгоо, антибиотикийн зөвлөмж гаргадаг.

DENDRAL

Химийн бодисын молекулын бүтцийг тодорхойлох систем

SPRINGER NATURE Link

Ашигт малтмалын хайгуулын компьютерт суурилсан зөвлөгөө өгөх систем



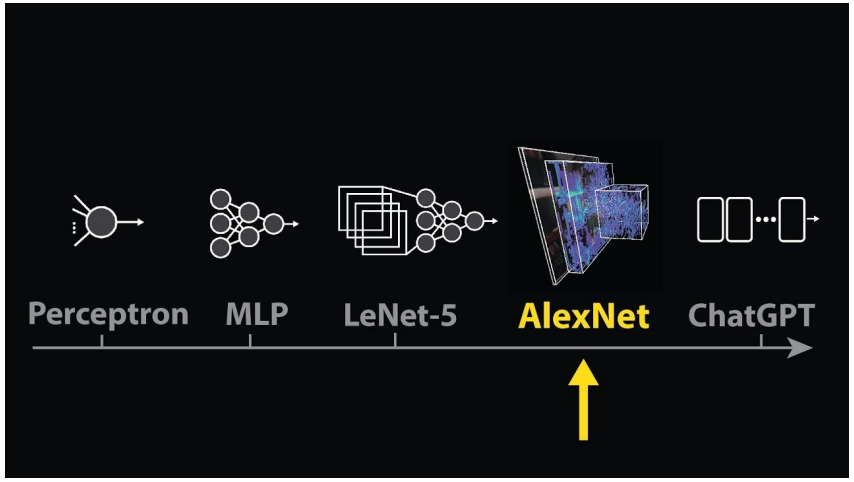
Компьютерийн тоног төхөөрөмжийн захиалгыг автоматаар тохируулах

Машин сургалтын түүх, хэрэглээ

- Өгөгдлийн эрин ба гүн сургалтын дэвшил (2000-2020)
  - 2006: Жеффри Хинтон гүн сургалтын (Deep Learning) нэр томьёог түгээмэл болгож, гүн мэдрэлийн сүлжээ (DNN) хөгжүүлэх шинэ аргачлалыг танилцуулсан.
  - 2012: Алекснет (AlexNet) гүн мэдрэлийн сүлжээг ашиглан ImageNet тэмцээнд ялж, компьютерийн харааны салбарт хувьсгал хийсэн.
  - 2014 он: Generative Adversarial Networks (GANs) загварууд хөгжиж, хиймэл дүрслэл, зураг үүсгэх боломжтой болов.



2016 Google's AlphaGo





Машин сургалтын түүх, хэрэглээ

- Өгөгдлийн эрин ба гүн сургалтын дэвшил (2000-2020)
  - 2016: AlphaGo хиймэл оюун ухаан нь Го-ын их мастерыг тоглоомд ялж, бие даан суралцах системийн боломжийг харуулав.
  - 2017 он: Transformers (e.g., BERT, GPT, T5) загварууд гарч, текст боловсруулалтад хувьсгал хийж, хэлний ойлголтыг сайжруулав.

  Гүн сургалт (Deep Learning), Big Data ашиглан AI маш өндөр түвшинд хүрсэн.



Шатар – Alpha Zero (DeepMind, 2018), Deep Blue (win Gary Kasparov, 1997)



Жолоочгүй машин (Tesla, Google, Apple, Ford, Audi, Huawei, Pony.ai, Kia-Hyundai)

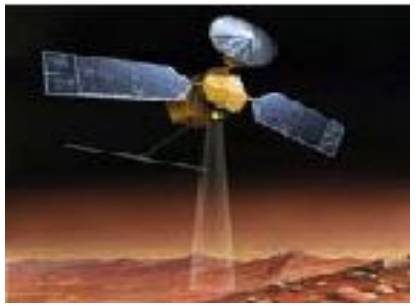


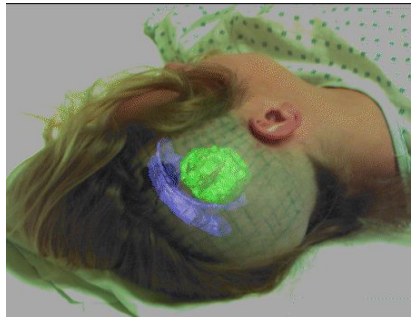


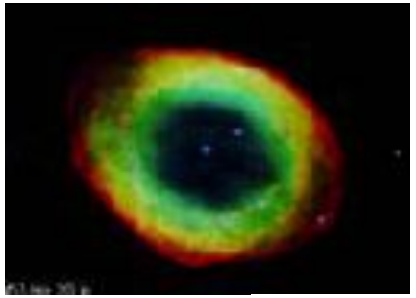


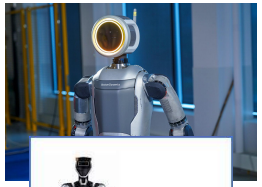
Машин сургалтын түүх, хэрэглээ

- Орчин үеийн хөгжил (2020 - одоо)
  - AGI (Artificial General Intelligence) буюу суурь хиймэл оюун ухааны хөгжүүлэлт эрчимжиж, ChatGPT, GPT-4, Google DeepMind зэрэг системүүд хүчирхэг болсон.
  - Хэлний том загварууд (LLM), агент AI (Agentic AI), бие даан шийдвэр гаргах AI хөгжиж байна.
  - Машин сургалт нь эрүүл мэнд, санхүү, автоматжуулалт, өөрөө жолооддог машин, томоохон өгөгдлийн анализ зэрэг олон салбарт өргөн хэрэглэгдэж байна.













Өгөгдөл

Өгөгдөл гэж юу вэ?

Өгөгдөл нь ямар нэгэн зүйл эсвэл үзэгдлийг тодорхойлсон, хадгалагдсан, боловсруулсан, анализ хийсэн мэдээлэл юм.

Өгөгдөл нь ямар нэгэн зүйл эсвэл үзэгдлийг тодорхойлсон, хадгалагдсан, боловсруулсан, анализ хийсэн мэдээлэл юм.

Өгөгдлийн төрлүүд

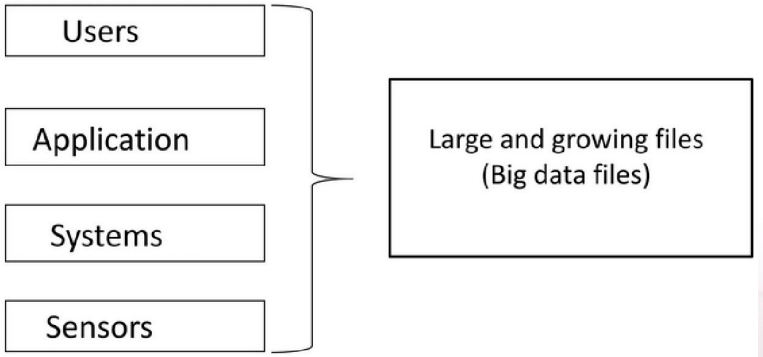
- Давтамж (Quantitative) өгөгдөл
- Чанар (Qualitative) өгөгдөл
- Цаг хугацааны өгөгдөл (Time-series data)
- Гео-өгөгдөл (Geospatial data)
- Текстийн өгөгдөл (Text data)
- Зураг, видео өгөгдөл (Image and video data)



Өгөгдөл

- Бүтэцлэгдсэн өгөгдөл (Structured Data): Тогтмол бүтэцтэй, тодорхой форматтай өгөгдөл. Жишээ нь, өгөгдлийн сан (SQL), хүснэгтүүд, баганатай мэдээлэл. Энэ төрлийн өгөгдөл нь хялбархан шинжлэх боломжтой.
- Түүхий өгөгдөл (Unstructured Data): Бүтэцгүй, зохион байгуулалтгүй өгөгдөл. Жишээ нь, текстийн бичлэгүүд, зураг, видео, аудио бичлэгүүд. Эдгээрийг боловсруулахад илүү төвөгтэй.
- Хагас бүтэцтэй өгөгдөл (Semi-structured Data): Бүтэцлэгдсэн өгөгдөлтэй харьцуулахад бага зэрэг эмх замбараагүй байж болно, гэхдээ тодорхой форматтай байдаг. Жишээ нь, JSON, XML, CSV файлууд.

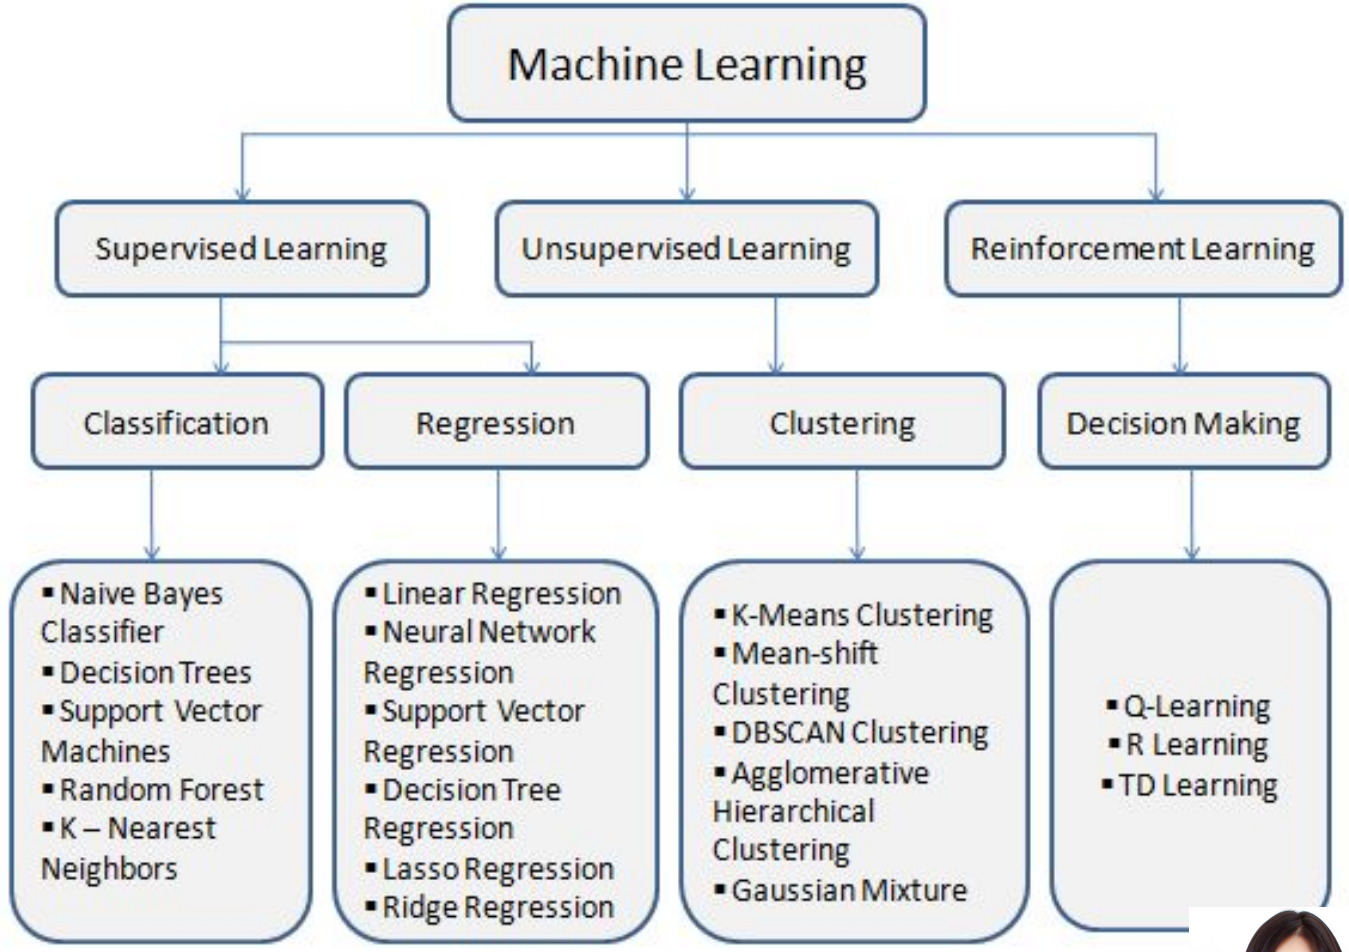


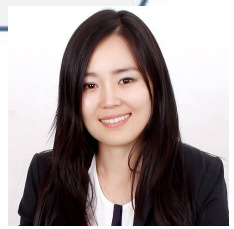




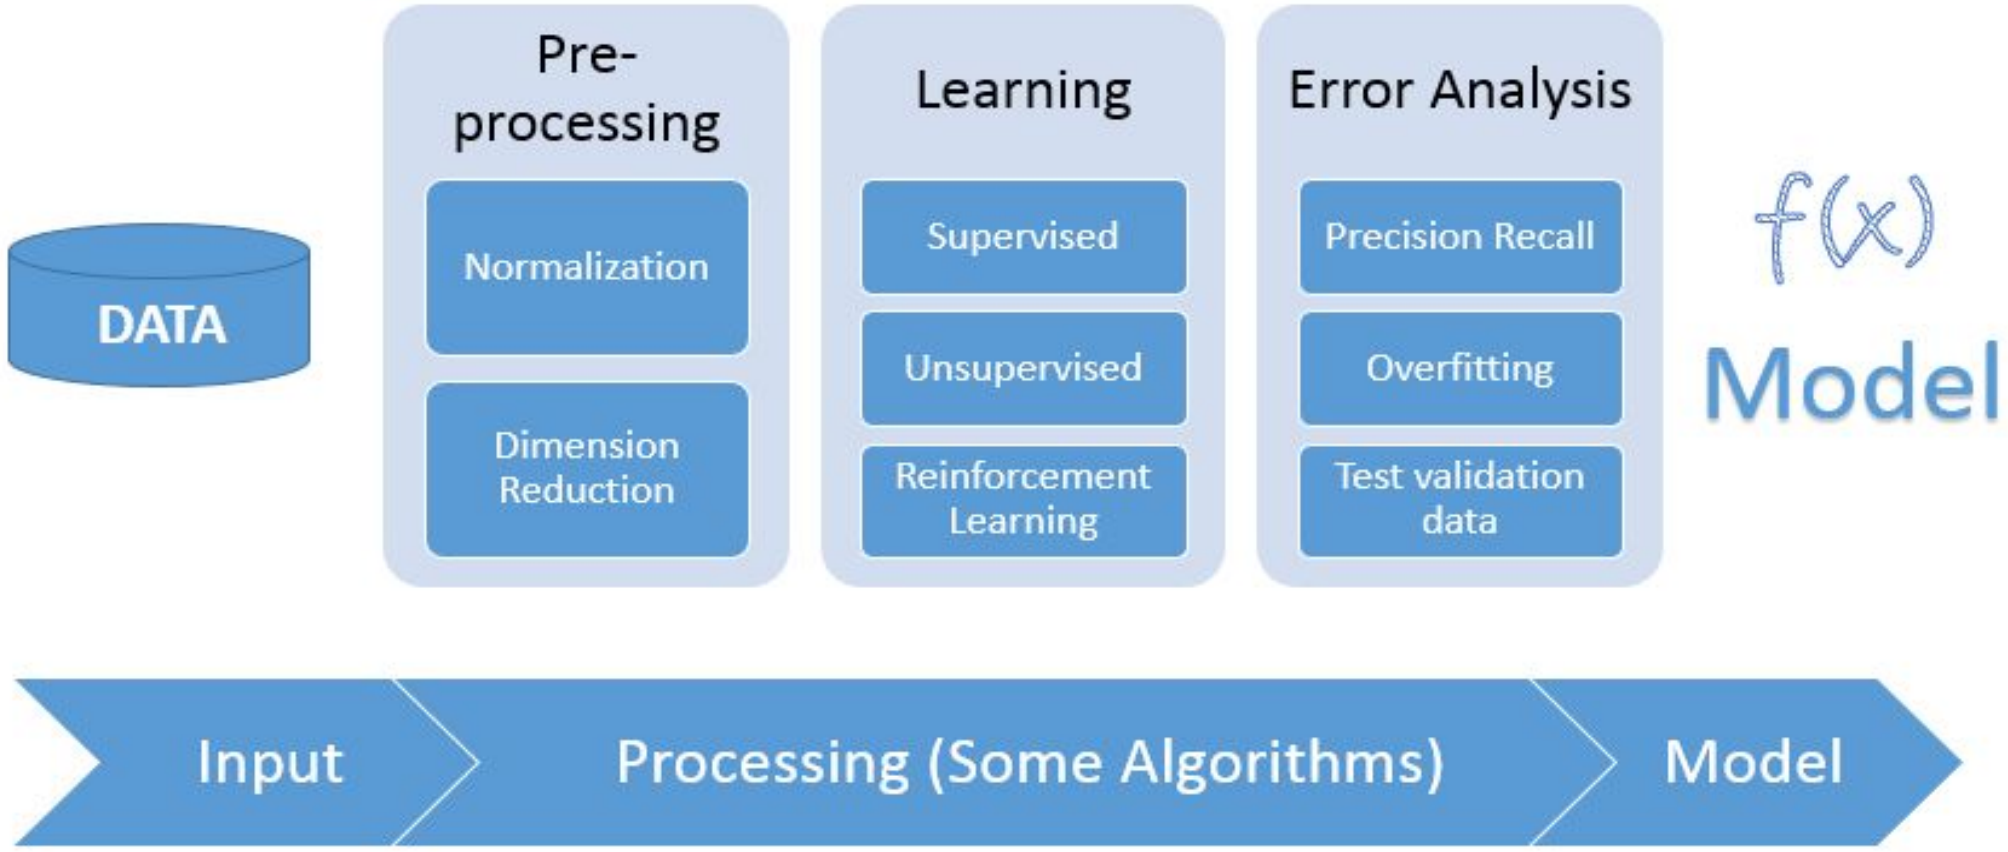
Машин сургалтын төрлүүд

- Удирдлагтай (индуктив) сургалт
  - Өгөгдсөн: сургалтын өгөгдөл + хүссэн үр дүн (шошго)
- Удирдлагагүй сургалт
  - Өгөгдсөн: сургалтын өгөгдөл (хүссэн үр дүн байхгүй)
- Хагас удирдлагатай сургалт
  - Өгөгдсөн: сургалтын өгөгдөл + цөөн хэдэн хүссэн үр дүн
- Reinforcement сургалт
  - Үйлдлүүдийн дараалалд урамшуулалт/оноо



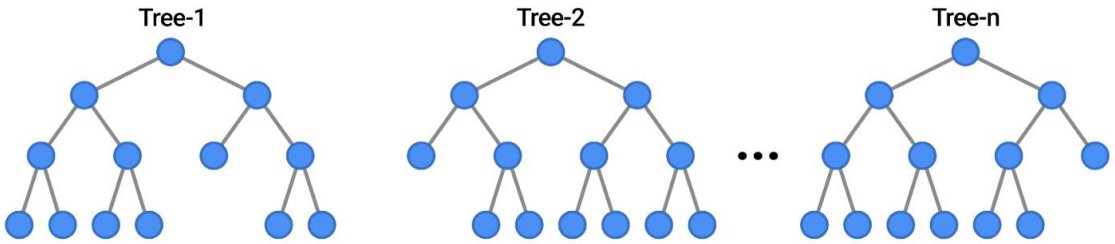


Машин сургалтын процесс

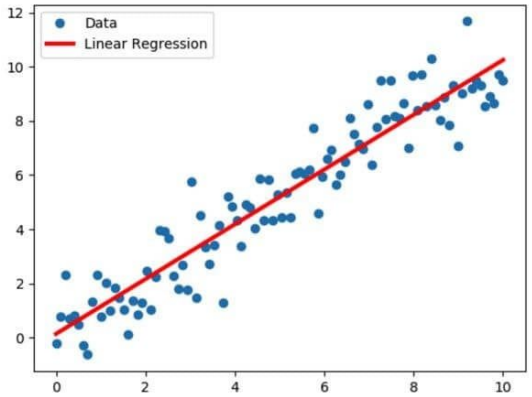




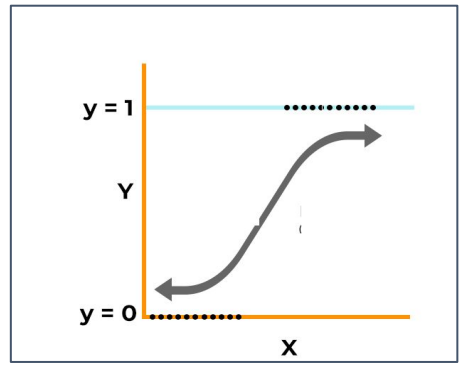
Удирдлагатай сургалтын загварууд



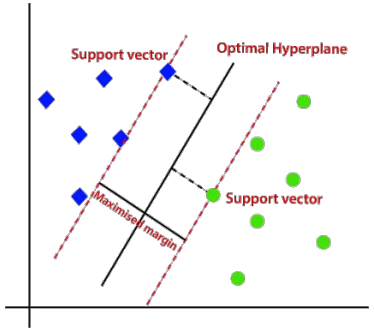
Random Forest



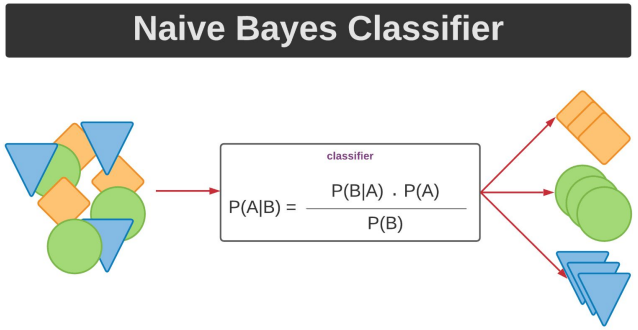
Linear regression



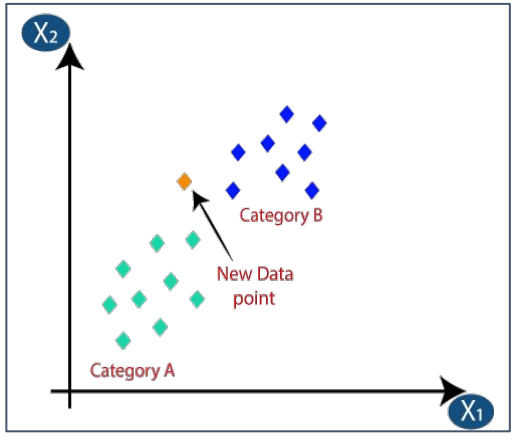
Logistic regression



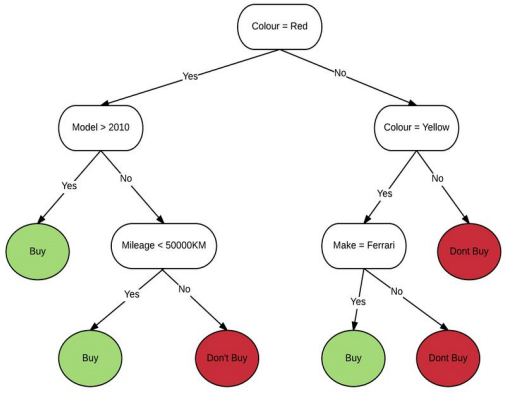
Support Vector Machine



Naive Bayes classifier



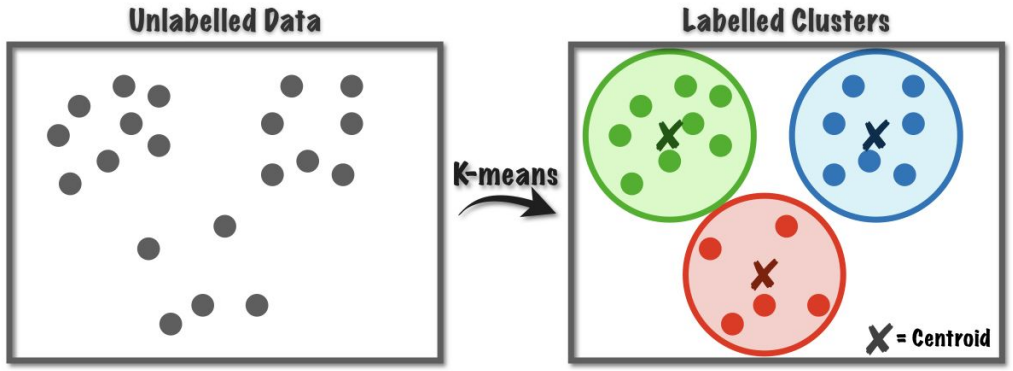
K-nearest neighbor



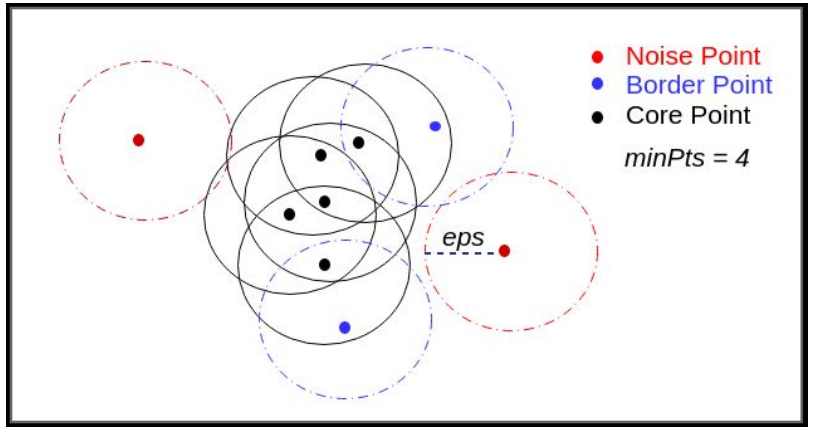
Decision Trees



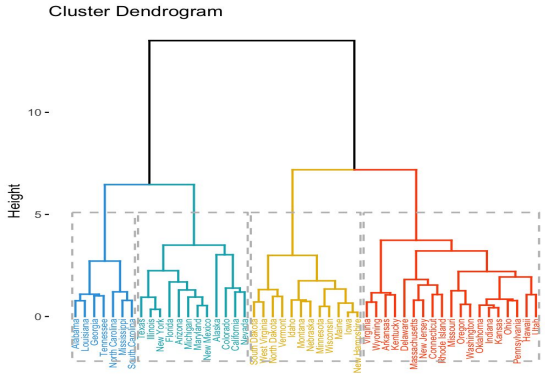
Удирдлагагүй сургалтын загварууд



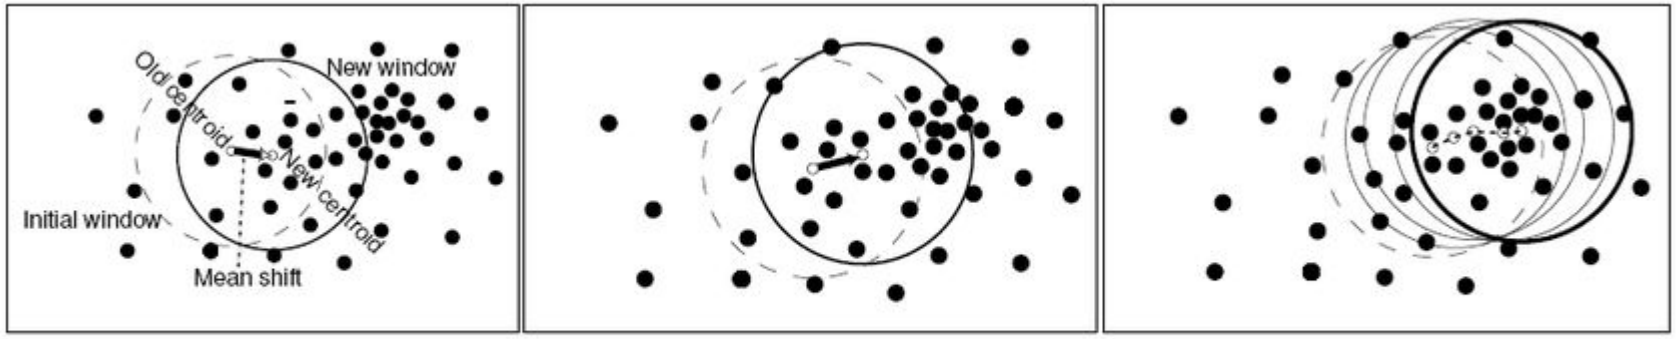
K-means clustering



DBScan clustering



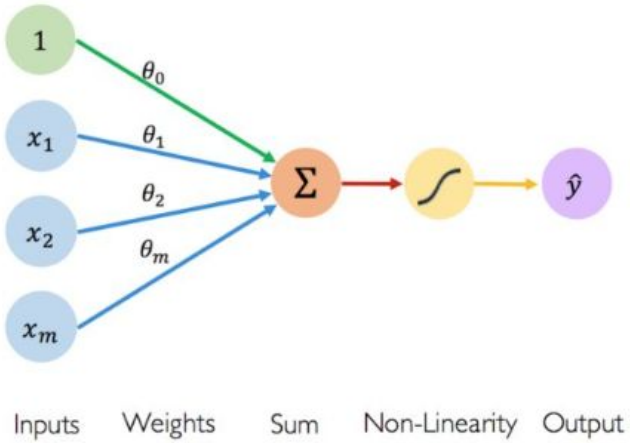
Agglomerative hierarchical clustering

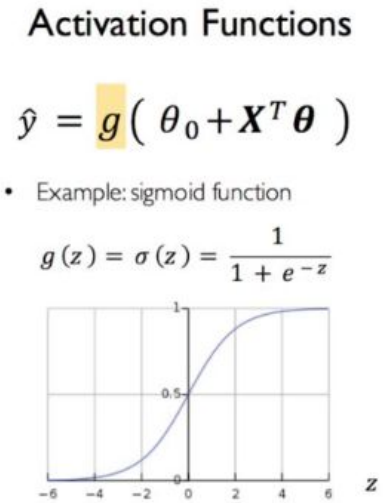


Mean-shift clustering



Хиймэл мэдрэлийн сүлжээ





$$y = f(W \cdot x + b)$$

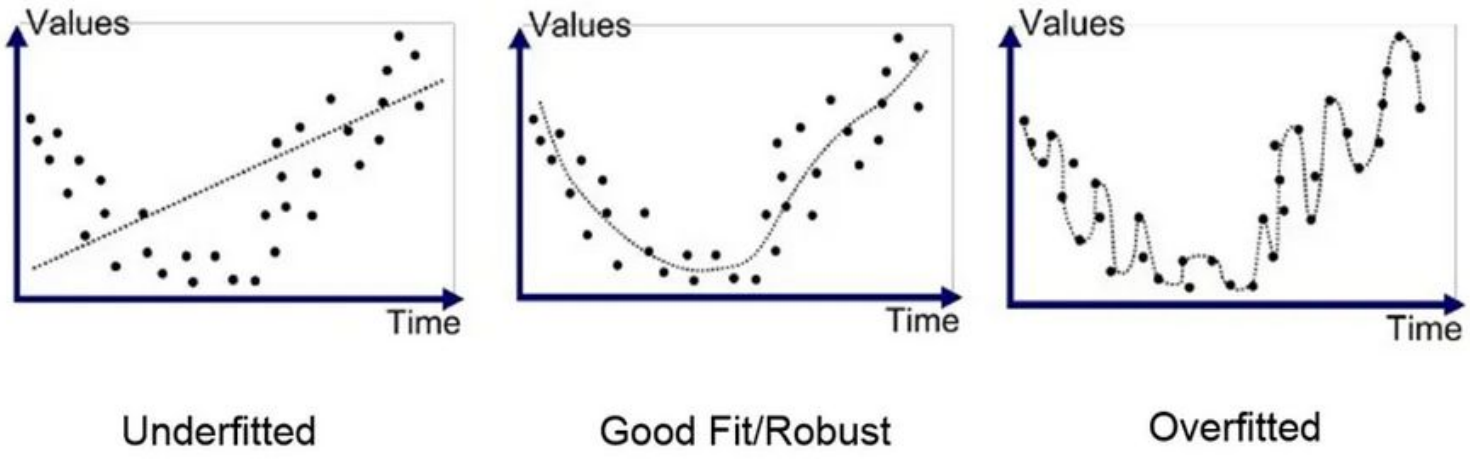
- x — оролтын вектор
- W — жин
- b — биас
- f — активацийн функц
- y — гаралт

Хиймэл мэдрэлийн сүлжээ нь хүний тархины мэдрэхүй болон сургалтын процесс-ийг дуурайхыг зорьсон тоон систем юм. Энэ нь олон нейрон буюу мэдрэлийн эс-ээс бүрдсэн бөгөөд тэдгээр нь мэдээллийг боловсруулж, хуулбарлах болон тайлбарлах үүрэгтэй. Хиймэл мэдрэлийн сүлжээ нь ихэвчлэн машин сургалт, deep learning болон pattern recognition зэрэг салбарт хэрэглэгддэг.



Модель сургалт ба үнэлгээ

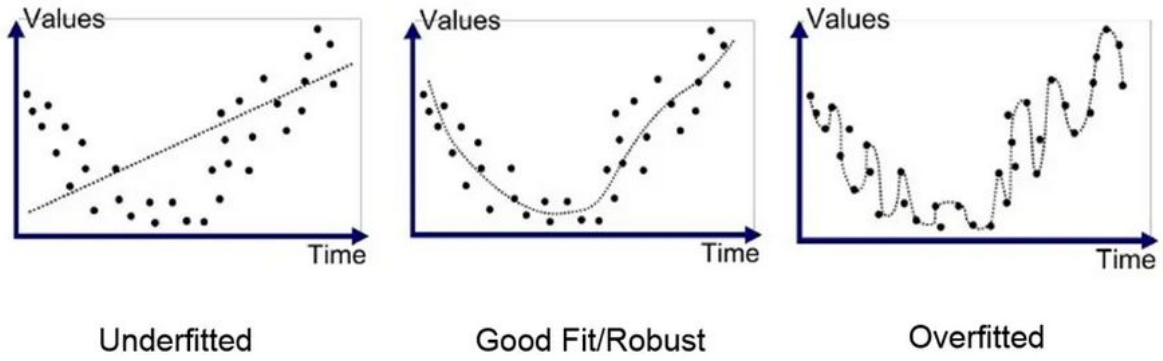
- Загварын гүйцэтгэлийг үнэлэх
  - Сургалтын өгөгдөл ба шалгалтын өгөгдөл
  - Нарийвчлал, үнэн зөв байдал (Accuracy, Precision, Recall, F1-score)
- Хэт тохирол (Overfitting) болон бага тохирол (Underfitting)





Машин сургалтын загварын үнэлгээ

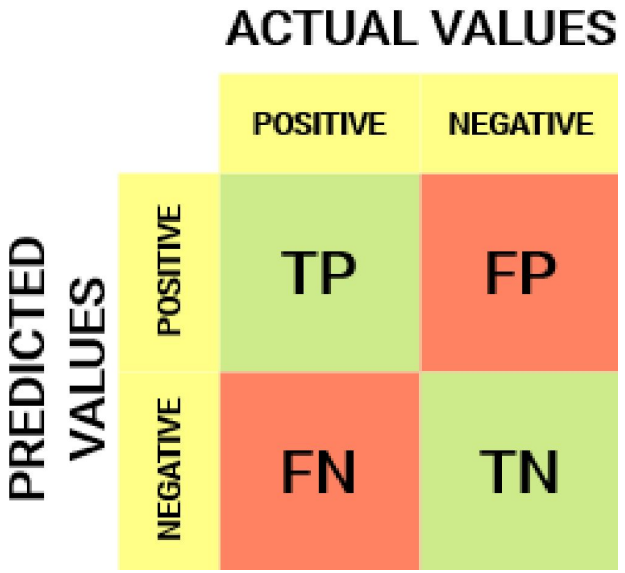
Машин сургалтын загварын гүйцэтгэлийг хэмжих нь үнэн зөв байдал (accuracy), алдааны түвшин (error), ерөнхий чадвар (generalization ability) зэрэг хүчин зүйлсийг ойлгоход чухал үүрэгтэй.





Машин сургалтын загварын үнэлгээ

- Төөрөгдөл матрикс нь ангилалуудыг зөв болон буруу ангилсан байдлыг дүрслэн харуулдаг матриц хэлбэрийн үнэлгээний хэрэгсэл юм.
- Энэ нь ангилалтын (classification) загваруудын гүйцэтгэлийг ойлгоход маш чухал.



- True Positive (TP) – Бодит эерэг утгыг зөв таньсан.
- False Positive (FP) – Бодит сөрөг утгыг буруу эерэг гэж ангилсан (Type I алдаа).
- False Negative (FN) – Бодит эерэг утгыг буруу сөрөг гэж ангилсан (Type II алдаа).
- True Negative (TN) – Бодит сөрөг утгыг зөв таньсан.



Машин сургалтын загварын үнэлгээ

Accuracy (Нарийвчлал)

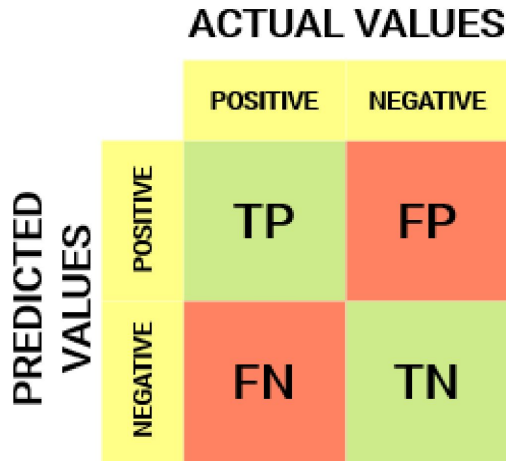
Бүх зөв таамаглалын эзлэх хувийг илэрхийлнэ. Давуу тал: Энгийн бөгөөд ерөнхий гүйцэтгэлийг харуулдаг. Сул тал: Өгөгдөлд тэнцвэргүй байдалтай үед (жишээ нь, нэг ангилалд их өгөгдөлтэй байх) төдийлөн ашигтай биш.



$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Онцлог

Гэвч өгөгдөл тэнцвэргүй (imbalanced data) үед энэ хэмжүүр хангалттай биш байж болно.



Машин сургалтын загварын үнэлгээ

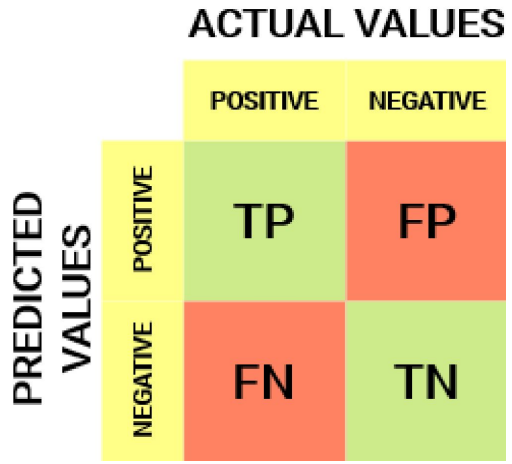
Precision (Нягтрал)

Загвар зөв эерэг (True Positive, TP) гэж ангилсан өгөгдөл хэр чанартай болохыг харуулна. Давуу тал: Зөв таамаглал чухал үед, жишээ нь, эмийн хуурамч зөвшөөрөл гаргахгүй байх

$$Precision = \frac{TP}{TP + FP}$$

Онцлог

Хуурамч эерэг (False Positive, FP) багасгахыг хүсвэл Precision чухал.





Машин сургалтын загварын үнэлгээ

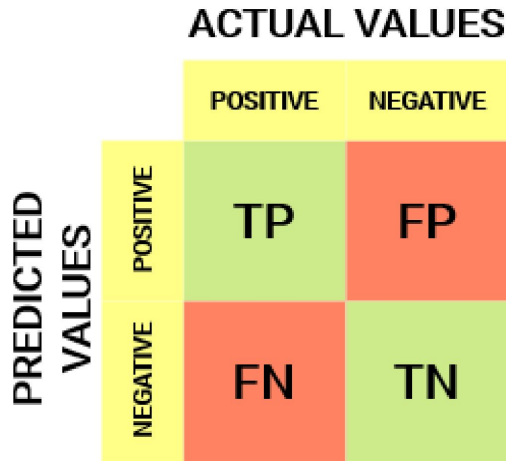
Recall

Бодит эерэг тохиолдлууд дундаас загвар хэдийг зөв ангилсныг хэмжинэ. Давуу тал: Сөрөг тохиолдол алдахгүй байх нь чухал үед, жишээ нь, хорт хавдрын шинжилгээнд.

$$Recall = \frac{TP}{TP + FN}$$

Онцлог

Өндөр Recall нь False Negative (FN) багасгах зорилготой.





Машин сургалтын загварын үнэлгээ

F1-score

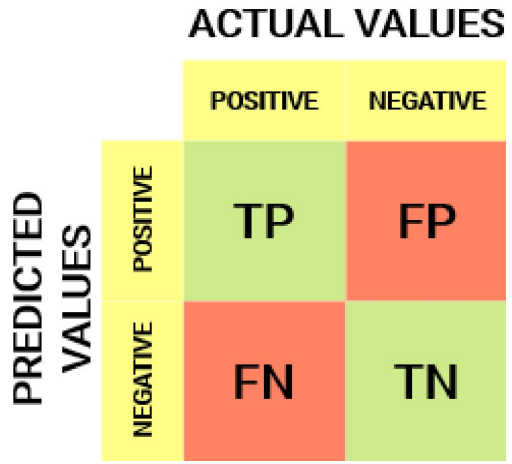
Precision ба Recall-ийн жигнэсэн дундаж.

Давуу тал: Нарийвчлал ба Recall хоёул чухал үед.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Онцлог

Тэнцвэргүй өгөгдөлтэй үед F1-score нь Accuracy-аас илүү бодитой хэмжүүр болдог.





Машин сургалтын загварын үнэлгээ

Жишээ

TP = 30, TN = 930, FP = 30, FN = 10

Accuracy = 0.96

Precision = 0.5

Recall = 0.75

F1 = 0.61



Өгөгдөл

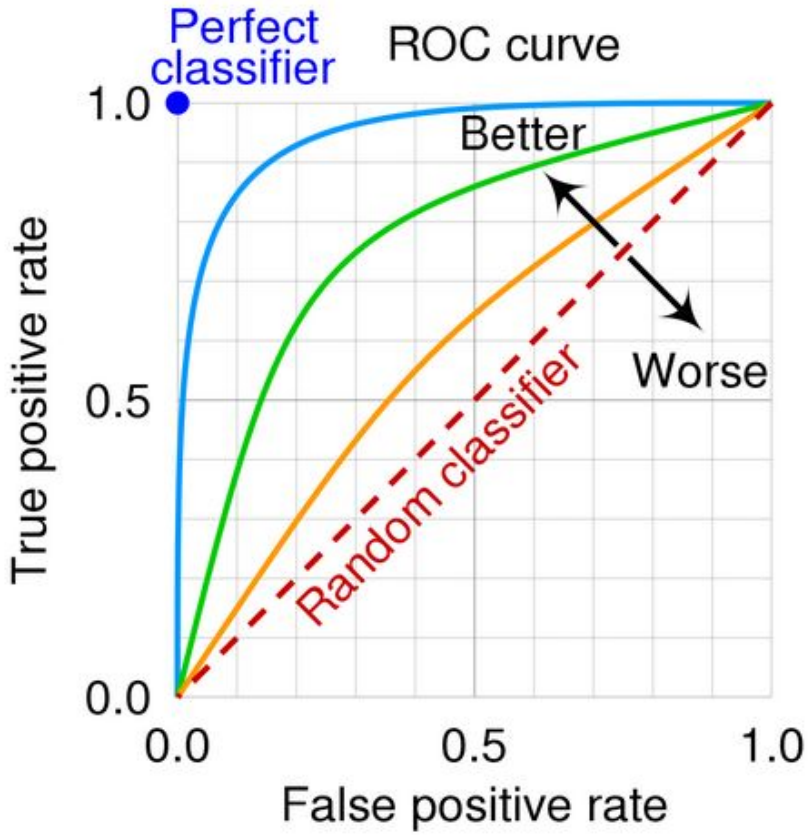
ID	Actual Sick?	Predicted Sick?	Outcome
1	1	1	TP
2	0	0	TN
3	0	0	TN
4	1	1	TP
5	0	0	TN
6	0	0	TN
7	1	0	FP
8	0	1	FN
9	0	0	TN
10	1	0	FP
:	:	:	:
1000	0	0	FN

Машин сургалтын загварын үнэлгээ

Алдаа шинжилгээ

ROC-AUC (Receiver Operating Characteristic - Area Under Curve)

- True Positive Rate (TPR) ба False Positive Rate (FPR) хоорондын хамаарлыг хэмждэг.
- AUC (Area Under Curve) өндөр байх тусам загвар сайн ажиллаж байна гэсэн үг.
- AUC (Area Under Curve): ROC муруйн доорх талбай, загварын сайн чанарыг илэрхийлнэ.
  - AUC = 1.0: Маш сайн загвар.
  - AUC = 0.5: Санамсаргүй таамаглалтай адил





Машин сургалтын загварын үнэлгээ

Mean Absolute Error (MAE)

Загварын таамаглалын дунджаар хэдий хэр алдаатай байгааг хэмжинэ.

$$MAE = \frac{1}{n}\sum |y_i - \hat{y}_i|$$

- y_i — **бодит утга** (real value)
- $\hat{y}_i$ — **таамаглалаас гарсан утга** (predicted value)
- n — **үнэлгээний өгөгдлийн тоо** (number of data points)

- MAE нь алдааг дундаж байдлаар үзүүлж, хэт их алдааг онцгойлон үзэхгүй.
- Хялбар ойлгогдох ба шууд үнэлгээний хэмжүүр.
- Эдгээрээс гадна, хэрвээ өгөгдөлд outliers байвал MSE эсвэл RMSE илүү тохиромжтой байж болно.



Машин сургалтын загварын үнэлгээ

Mean Squared Error (MSE)

Алдааны квадратын дундаж утга. MSE нь алдааны квадрат (squared error)-г тооцож, бүх алдааг нэгэн адил хүчтэй онцолдог.

$$MSE = \frac{1}{n}\sum(y_i - \hat{y}_i)^2$$

- y_i — **бодит утга** (real value)
- $\hat{y}_i$ — **таамаглалаас гарсан утга** (predicted value)
- n — **үнэлгээний өгөгдлийн тоо** (number of data points)

- Алдаа их байх тусам MSE өндөр болдог учир outliers буюу хэт их алдаануудын нөлөөг мэдэрч болно.
- MSE нь өөрчлөлтийн хурдацтай өсөх онцлогтой, энэ нь оновчтой загвар сонгоход тусална.
- MSE нь зөвхөн алдааны хэмжээ-г хэлж өгөхөөс гадна, алдааг хэтрүүлэн хэмжих чадвартай.
- Outliers болон хэт том алдаа-г онцгойлон харгалзан үзэх үед MSE нь илүү тохиромжтой.



Машин сургалтын загварын үнэлгээ

Root Mean Squared Error (RMSE)

MSE-ийн квадрат язгуур, MAE-тай төстэй боловч том алдааг онцгойлон авч үздэг.

$$RMSE = \sqrt{MSE}$$

- y_i — **бодит утга** (real value)
- $\hat{y}_i$ — **таамаглалаас гарсан утга** (predicted value)
- n — **үнэлгээний өгөгдлийн тоо** (number of data points)

- Энэ нь алдагдал болон зөрүү-г үндсэн нэгжид буцааж өгдөг, ингэснээр үнэлгээ нь илүү ойлгомжтой болдог.
- RMSE нь алдагдал их байвал илүү өндөр утгатай, мөн алдагдлыг хүндээр онцлог үзүүлдэг.
- RMSE нь MSE-ийн адил алдааг онцолдог ч, нэгжийн хэмжигдэхүүнтэй харьцуулахад илүү тохиромжтой байдаг.
- Энэ нь судалгааны загвар болон огцом алдаа-нд анхаарал хандуулдаг.



Машин сургалтын загварын үнэлгээ

R^2 Score (R-Squared, Coefficient of Determination)

Загвар өгөгдлийн хэлбэлзлийг тайлбарлаж чадаж байгаа эсэхийг хэмждэг.

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

- y_i — **бодит утга** (real value)
- $\hat{y}_i$ — **таамаглалаас гарсан утга** (predicted value)
- $\bar{y}$ — **бодит утгын дундаж** (mean of actual values)
- n — **үнэлгээний өгөгдлийн тоо** (number of data points)



- $R^2 = 1$ нь загвар мөнхүү таамаглал нь бодит утга-тай яг тохирч байгаа гэсэн үг.
- $R^2 = 0$ нь загвар нь огт таамаглал хийхгүй байгаа, эсвэл ямар ч холбоогүй байгааг илэрхийлдэг.
- $R^2 < 0$ нь загвар дараагийн таамаглалтай холбоотой бүрэн буруу буюу тогтворгүй байна гэсэн үг.
- R^2 Score нь регрессийн загваруудын гүйцэтгэлийг бодит болон таамагласан утгуудын хоорондын харьцааг ойлгуулахад тохиромжтой.
- Олон бүрэлдэхүүнтэй загвар, эсвэл хамгийн сайн тохирсон загвар сонгоход хэрэглэгддэг.

Удирдлагатай сургалтын үнэлгээ

- Log Loss (Logarithmic Loss): Загварын магадлалт таамаглалыг хэр үнэн зөв болохыг хэмждэг.
- Томьёо:

$$Log\ Loss = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)]$$

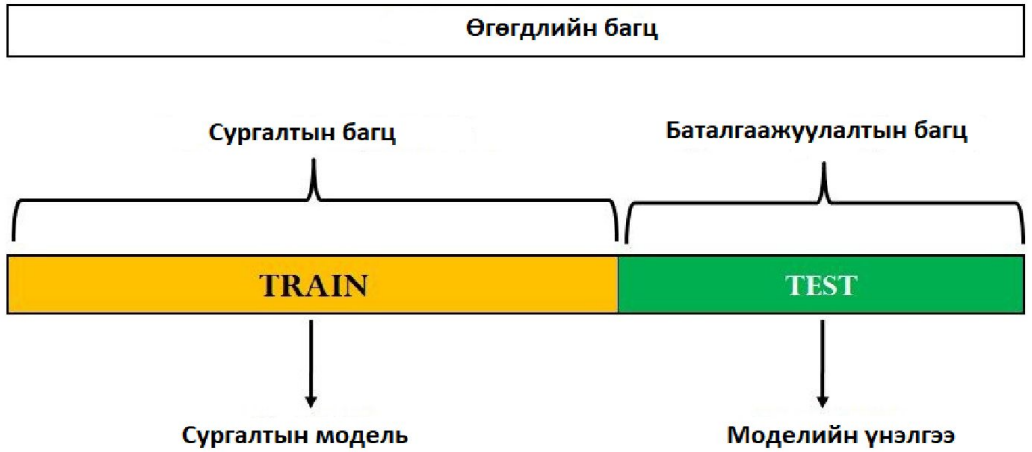
- Магадлалт гаралтад (probabilistic output) тохиромжтой.



Загварын үнэлгээний аргууд

Holdout баталгаажуулалт

- Өгөгдлийг сургалтын (train), шалгалтын (test) хэсэгт хуваах.
- Стандарт хуваалт: 80% train - 20% test эсвэл 70% train - 30% test.
- Сургалтын багц нь тухайн загварыг сургасан зүйл бөгөөд туршилтын багцыг тухайн үл үзэгдэх өгөгдөл дээр хэр сайн гүйцэтгэж байгааг харах зорилгоор ашигладаг.



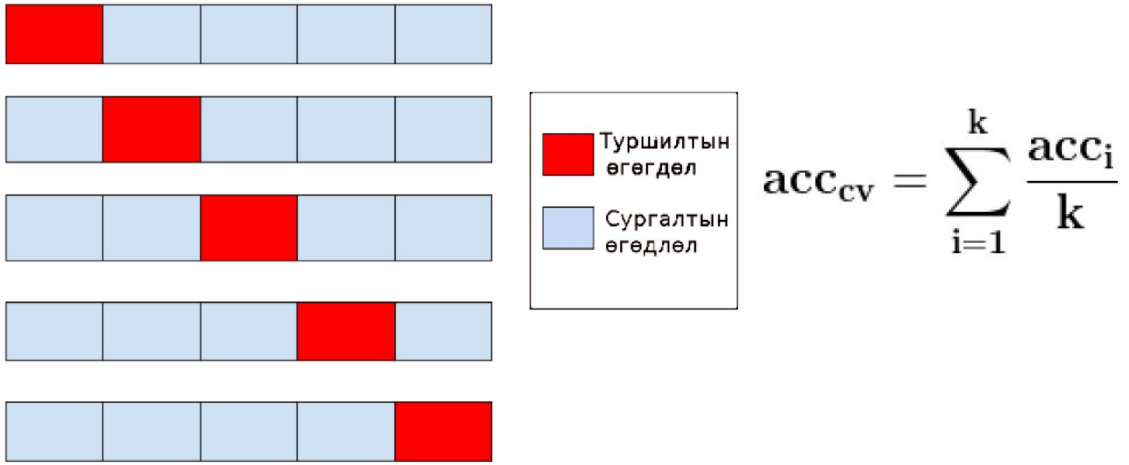
- Hold-out арга нь маш том өгөгдлийн сантай үед, цаг хугацааны хомсдолд орсон, эсвэл мэдээллийн шинжлэх ухааны төсөлдөө анхны моделио бүтээж эхлэхэд ашиглахад тохиромжтой.



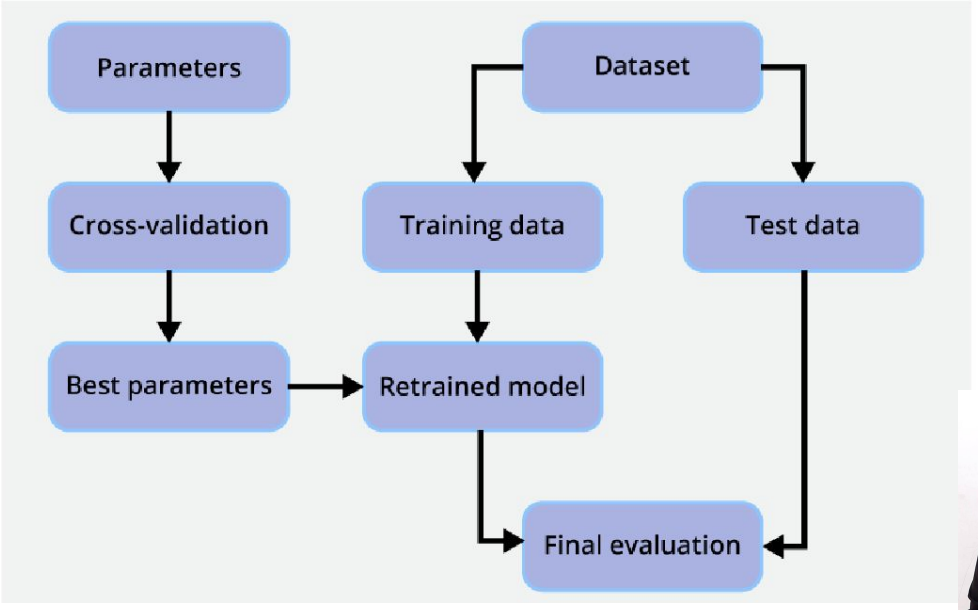
Загварын үнэлгээний аргууд

K-Fold Cross Validation

- Өгөгдлийг K хэсэгт хуваагаад, K-1 хэсгийг сургалт, 1 хэсгийг шалгалтад ашиглана.
- 5-fold эсвэл 10-fold CV ихэвчлэн хэрэглэгддэг.



$$acc_{cv} = \sum_{i=1}^{k} \frac{acc_i}{k}$$

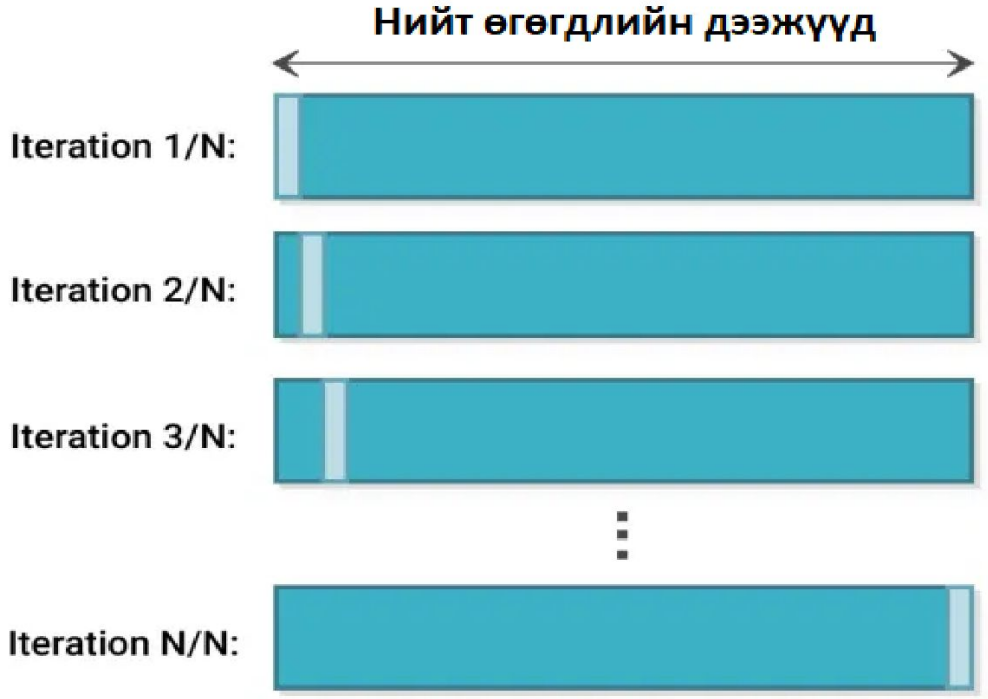




Загварын үнэлгээний аргууд

Leave-One-Out Cross Validation (LOOCV)

- N өгөгдөлтэй бол N-1 өгөгдлөөр сургаж, үлдсэн 1-ээр шалгах.
- Алдаа багатай ч их хэмжээний тооцоолол шаарддаг.





Загварын үнэлгээний аргууд

Stratified K-Fold Cross Validation

- Өгөгдлийн ангиудын харьцааг хадгалан K-fold validation хийх арга.
- Тэнцвэргүй өгөгдөлтэй үед илүү найдвартай.





Дүгнэлт

- Машин сургалт нь орчин үеийн технологи, шинжлэх ухаан, бизнес, нийгмийн олон салбарт хувьсгал хийж буй хүчирхэг аргачлал юм.
- Машин сургалт нь өгөгдлөөс суралцаж, таамаглал хийх чадвартай загваруудыг боловсруулдаг.
- Загварын гүйцэтгэлийг үнэлэхэд төөрөгдөл матрикс, Precision, Recall, F1-Score зэрэг хэмжүүрүүдийг ашигладаг.
- Баталгаажуулалт нь загварын overfitting-ийг хязгаарлах, генералчлал-ын чадварыг шалгах ач холбогдолтой.
- Сайн загвар нь зөвхөн accuracy биш, олон хэмжүүр дээр сайн ажилладаг байх ёстой.

