ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ
Мэдээлэл холбооны технологийн сургууль



ЛАБОРАТОРИЙН АЖЛЫН ТАЙЛАН

Хиймэл оюуны үндэс
2026-2027 оны хичээлийн жилийн намар

Лабораторийн ажлын нэр: Лабораторийн ажил №4
Агент: энгийн рефлекс агент, орчны агент, Multi-modal агент (дүрс → текст → дуу хоолой)

Шалгасан багш: Э.Батцэцэг /...../

Гүйцэтгэсэн: Оюутан: Ц.Номинжин - B241940137 /...../

Авбал зохих нийт оноо:	**15 оноо**		
Гүйцэтгэлийн шалгуур	**Үнэлгээний эзлэх хувь**	**CLOs хамаарал**	**Багшийн үнэлгээ**
Хичээлийн ирц/оролцоо	10%		
Энгийн болон орчны агентийн даалгавар	20%		
Multi-modal агентийн даалгавар	20%		
Дүрс + Дуу хоолой (gTTS) хэрэгжүүлэлт	30%		
Лабораторийн тайлан бичилт, хамгаалалт	20%		
Үнэлгээний нийт хувь			
Нийт авсан оноо			

ТОЙМ

Лабораторийн ажлын зорилго нь хиймэл оюуны агент (agent)-ийн мэдрэх–шийдэх–үйлдэх зарчмыг Python хэл дээр хэрэгжүүлж турших явдал байв. Эхлээд «If–Then» дүрэмд суурилсан `WeatherAgent` ба `EnvironmentAgent` энгийн агентуудыг бичиж, гараас оруулсан өгөгдөлд хариу үйлдэл үзүүлэхийг шалгасан: цаг агаар «rainy» үед «Борооны шүхэр аваарай!», бохирдлын түвшин 75 үед «Бохирдол өндөр байна. Агаар шүүгч асаана уу.» гэсэн шийдвэр гарсан. Дараа нь Hugging Face-ийн `nlpconnect/vit-gpt2-image-captioning` (ViT encoder + GPT-2 decoder) загварыг ашиглан дүрс болон текстийг хослуулан боловсруулдаг Multi-modal агент үүсгэв. Агент нь `sample_image.jpg` нохойн зургийг «a brown and white dog with a red collar» гэж зөв тайлбарлаж, gTTS сангаар уг тайлбарыг `caption_audio.mp3` аудио файл болгон хадгалж, `mpv`-ээр алдаагүй (exit status 0) тоглуулсан. Ubuntu 24.04 орчинд гарсан externally-managed-environment ба `click` сангийн хувилбарын зөрчлийг виртуал орчин (`venv`) үүсгэж шийдвэрлэсэн. Дүрмийн агент нь урьдчилан тодорхойлсон нөхцөлд хурдан, найдвартай ажилладаг ч уян хатан бус, харин Multi-modal агент нь агентийн мэдрэх, үйлдэх чадварыг дүрс ба дуу хоолойн түвшинд өргөжүүлж болохыг харуулав.

ГАРЧИГ

ТОЙМ..... 1
ЗУРГИЙН ЖАГСААЛТ.....3
ХҮСНЭГТИЙН ЖАГСААЛТ.....4
1. АЖЛЫН ЗОРИЛГО БА ОНОЛЫН ОЙЛГОЛТ.....5
1.1. Ажлын зорилго.....5
1.2. Агент ба орчин.....5
1.3. Энгийн рефлекс агент.....5
1.4. Multi-modal агент.....6
1.5. Vision-Encoder-Decoder загвар.....6
1.6. Текстийг яриа болгох (gTTS).....6
2. ХЭРЭГЛЭГДЭХҮҮН.....6
3. ХЭМЖИЛТ, ТУРШИЛТ ХИЙСЭН ДАРААЛАЛ.....7
3.1. Орчин бэлтгэх.....7
3.2. Энгийн болон орчны агент.....8
3.3. Multi-modal агент.....8
4. ХЭМЖИЛТ, ТУРШИЛТЫН ҮР ДҮНГҮҮД.....9
4.1. Энгийн болон орчны агентийн үр дүн.....9
4.2. Multi-modal агентийн үр дүн.....10
5. ХЭЛЭЛЦҮҮЛЭГ..... 11
5.1. Дүрмийн агентийн шинжилгээ.....11
5.2. Multi-modal агентийн шинжилгээ.....11
5.3. Туршилтын явцад гарсан асуудал.....12
5.4. Зорилтод хүрсэн байдал.....12
6. ДҮГНЭЛТ.....13
7. АШИГЛАСАН МАТЕРИАЛ.....14

ЗУРГИЙН ЖАГСААЛТ

Зураг 1.1. Агент ба орчны мэдрэх–үйлдэх мөчлөг.....5
Зураг 1.2. ViT–GPT-2 Vision-Encoder-Decoder загварын бүтэц.....6
Зураг 2.1. Лаб 4-ийн ажлын хавтасны бүтэц.....7
Зураг 3.1. Multi-modal агентийн ажиллах дараалал.....8
Зураг 3.2. `vision_agent.py` программын код (IDLE засварлагч).....9
Зураг 4.1. `vision_agent.py`-ийн гаралт (IDLE Shell).....10
Зураг 4.2. `caption_audio.mp3`-ийг `mpv`-ээр тоглуулсан байдал (терминал).....10

ХҮСНЭГТИЙН ЖАГСААЛТ

Хүснэгт 1.1. Лабораторид хэрэгжүүлсэн агентуудын харьцуулалт.....5
Хүснэгт 2.1. Хэрэглэгдсэн программ хангамж, сан, файлууд.....7
Хүснэгт 4.1. Энгийн болон орчны агентийн туршилтын үр дүн.....9
Хүснэгт 4.2. Multi-modal агентийн оролт ба гаралт.....11
Хүснэгт 5.1. Туршилтын явцад гарсан асуудал ба шийдэл.....12

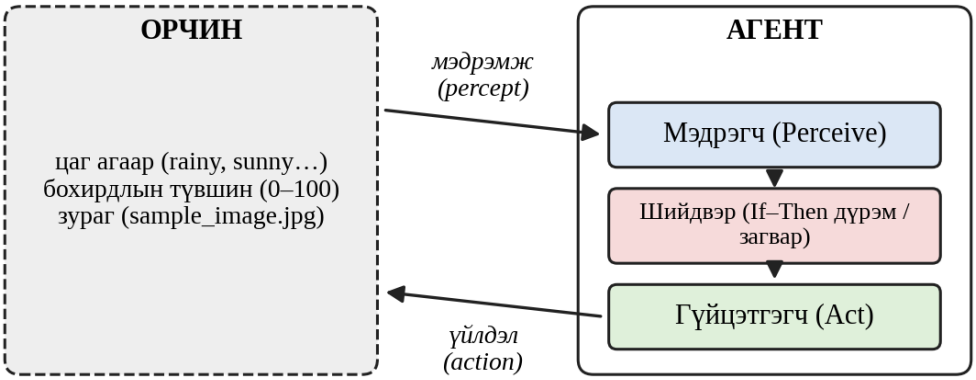
1. АЖЛЫН ЗОРИЛГО БА ОНОЛЫН ОЙЛГОЛТ

1.1. Ажлын зорилго

Лабораторийн ажлын зорилго нь орчны өгөгдөлд үндэслэн шийдвэр гаргадаг дүрмийн суурьтай энгийн агентуудыг хөгжүүлэх, мөн дүрс ба текстийн өгөгдлийг зэрэг боловсруулах чадвартай Multi-modal агентийн ажиллагааны зарчмыг практикт судалж, аудио гаралттай холбоход оршино [1]. Ажлыг энгийн (рефлекс) агент, орчны агент, Multi-modal агент гэсэн гурван хэсэгт хуваж гүйцэтгэсэн бөгөөд тайланг [2]-т заасан загварын дагуу бэлтгэв.

1.2. Агент ба орчин

Агент (agent) нь орчноосоо мэдрэгчээр дамжуулан мэдээлэл хүлээн авч (perceive), өөрийн дүрэм эсвэл загварын дагуу шийдвэр гаргаж, гүйцэтгэгчээр дамжуулан орчинд үйлдэл үзүүлдэг (act) систем юм [3]. Агентийн тухайн агшинд хүлээн авсан ороолтыг мэдрэмж (percept) гэх ба агентийн зан төлөвийг мэдрэмжийн дарааллаас үйлдэл рүү буулгах агентийн функцээр тодорхойлно. Лабораторийн ажилд орчин нь цаг агаарын төлөв, бохирдлын түвшин болон зургийн файл байсан (Зураг 1.1).



Зураг 1.1. Агент ба орчны мэдрэх–үйлдэх мөчлөг

1.3. Энгийн рефлекс агент

Энгийн рефлекс агент (simple reflex agent) нь зөвхөн одоогийн мэдрэмжид тулгуурлан «If–Then» (нөхцөл–үйлдэл) дүрмээр шийдвэр гаргадаг хамгийн энгийн бүтэцтэй агент юм [3]. Өмнөх төлөвөө санадаггүй тул орчин бүрэн ажиглагдах, дүрмүүд нь бүх боломжит нөхцөлийг хамарсан үед л зөв ажиллана. Лабораторид `WeatherAgent` (цаг агаарын төлөвөөс хамаарч зөвлөмж өгөх) ба `EnvironmentAgent` (бохирдлын түвшнээс хамаарч агаар шүүгч асаах эсэхийг шийдэх) гэсэн хоёр ийм агент хэрэгжүүлсэн. Хэрэгжүүлсэн агентуудыг Хүснэгт 1.1-д харьцуулав.

Хүснэгт 1.1. Лабораторид хэрэгжүүлсэн агентуудын харьцуулалт

Агент	Мэдрэх (оролт)	Шийдвэр гаргах арга	Үйлдэл (гаралт)
`WeatherAgent`	цаг агаарын төлөв (текст, жишээ нь rainy)	If–Then дүрэм	текст зөвлөмж
`EnvironmentAgent`	бохирдлын түвшин (тоо)	If–Then дүрэм, босго утгатай харьцуулах	текст шийдвэр (агаар шүүгч асаах)

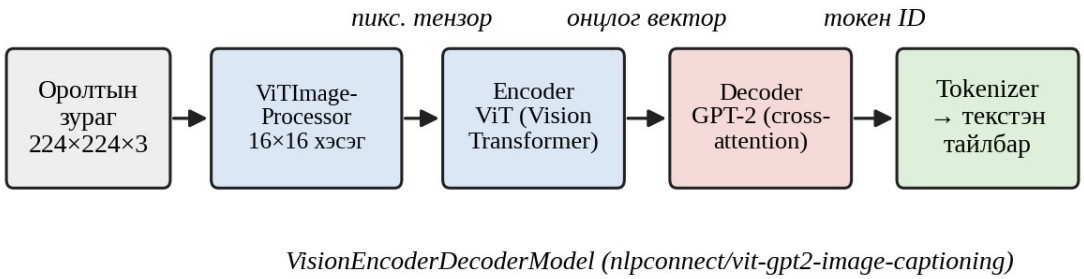
Агент	Мэдрэх (оролт)	Шийдвэр гаргах арга	Үйлдэл (гаралт)
Multi-modal агент	зураг (`sample_image.jpg`)	урьдчилан сургасан ViT–GPT-2 нейрон сүлжээ	англи текст тайлбар ба MP3 аудио

1.4. Multi-modal агент

Multi-modal агент нь текст, дүрс, дуу хоолой зэрэг олон төрлийн (modality) өгөгдлийг нэгэн зэрэг хүлээн авч боловсруулах чадвартай хиймэл оюуны систем юм. Лабораторийн ажилд агент нь дүрсийг мэдэрч (оролт), түүнийг текст тайлбар болгон боловсруулж, эцэст нь дуу хоолой хэлбэрээр орчинд үйлдэл үзүүлсэн. Ингэснээр нэг агентийн дотор дүрс → текст → яриа гэсэн гурван modality хооронд хөрвүүлэлт явагдана.

1.5. Vision-Encoder-Decoder загвар

Зургийн тайлбар үүсгэх (image captioning) даалгаварт `VisionEncoderDecoderModel` архитектурыг ашигласан [6], [7]. Энэ архитектурт encoder хэсэг нь зургийг 16×16 пикселийн хэсгүүдэд хувааж, хэсэг бүрийг токен мэт боловсруулдаг Vision Transformer (ViT) [4], decoder хэсэг нь өмнөх үгсийн дагуу дараагийн үгийг таамагладаг GPT-2 хэлний загвар [5] байна. Decoder нь cross-attention механизмаар encoder-ийн гаргасан онцлог векторуудад хандаж, зурагт тохирсон өгүүлбэрийг үг үгээр үүсгэнэ (Зураг 1.2). Ажилд ашигласан `nlpconnect/vit-gpt2-image-captioning` загвар нь англи хэл дээр тайлбар үүсгэхээр урьдчилан сургагдсан [6].



Зураг 1.2. ViT–GPT-2 Vision-Encoder-Decoder загварын бүтэц

1.6. Текстийг яриа болгох (gTTS)

gTTS (Google Text-to-Speech) нь Google Translate-ийн яриа нийлэгжүүлэх үйлчилгээтэй харилцдаг Python сан бөгөөд өгсөн текстийг заасан хэл дээр (`lang` параметр) MP3 аудио болгон хадгалдаг [8]. Сан нь интернэт холболт шаарддаг. Лабораторид загварын үүсгэсэн англи тайлбарыг gTTS-ээр аудио файл болгон хөрвүүлж, агентийн «дуу хоолойн» гаралтыг бий болгосон.

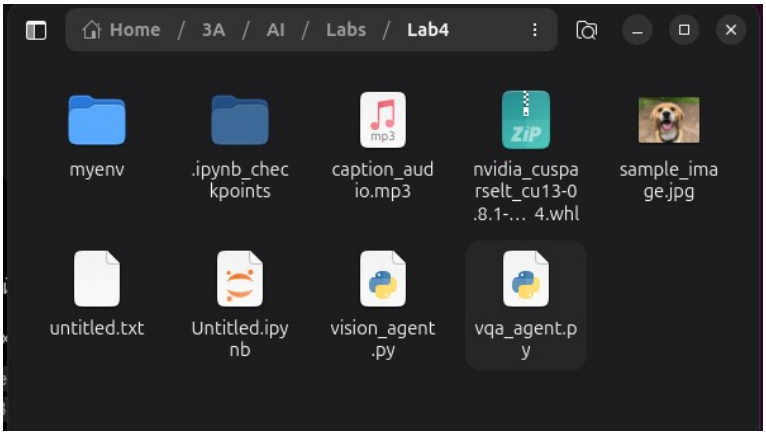
2. ХЭРЭГЛЭГДЭХҮҮН

Лабораторийн ажлыг гүйцэтгэхэд ашигласан программ хангамж, сан, файлуудыг Хүснэгт 2.1-д жагсаав.

Хүснэгт 2.1. Хэрэглэгдсэн программ хангамж, сан, файлууд

№	Хэрэгсэл	Тодорхойлолт	Зориулалт
1	Үйлдлийн систем	Ubuntu Linux 24.04 LTS	программ ажиллуулах орчин
2	Python, IDLE	Python 3.14.4, IDLE 3.14.4	код бичих, ажиллуулах
3	Виртуал орчин	`python3-venv`, `myenv`	сангуудыг системээс тусгаарлан суулгах [9]
4	torch (PyTorch)	машин сургалтын тооцооллын сан	загварын тензор тооцоолол
5	transformers	Hugging Face сан	урьдчилан сургасан загвар, процессор, токенайзер ачаалах [7]
6	Pillow (PIL)	зураг боловсруулах сан	зургийг уншиж RGB болгох
7	gtts	Google Text-to-Speech сан	текстийг MP3 аудио болгох [8]
8	Загвар	`nlpconnect/vit-gpt2-image-captioning`	зургийн тайлбар үүсгэх [6]
9	mpv	медиа тоглуулагч	`caption_audio.mp3` тоглуулах
10	Өгөгдлийн файл	`sample_image.jpg`	Multi-modal агентийн оролт (нохойн зураг)
11	Программын файл	`vision_agent.py`	Multi-modal агентийн эх код

Ажлын бүх файлыг `~/3A/AI/Labs/Lab4` хавтсанд байрлуулсан. Хавтсанд виртуал орчин (`myenv`), оролтын зураг (`sample_image.jpg`), программын код (`vision_agent.py`) болон программын үүсгэсэн аудио файл (`caption_audio.mp3`) байгааг Зураг 2.1-д үзүүлэв.



Зураг 2.1. Лаб 4-ийн ажлын хавтасны бүтэц

3. ХЭМЖИЛТ, ТУРШИЛТ ХИЙСЭН ДАРААЛАЛ

Туршилтыг орчин бэлтгэх, энгийн агентууд бичих, Multi-modal агент үүсгэх гэсэн гурван үе шаттайгаар гүйцэтгэсэн.

3.1. Орчин бэлтгэх

1) Ubuntu систем дээр `pip install` шууд ажиллуулахад externally-managed-environment алдаа гарсан тул `python3-venv` ашиглан `myenv` виртуал орчин үүсгэж идэвхжүүлсэн [9], [10].
2) Виртуал орчин дотор `torch`, `transformers`, `pillow`, `gtts` сангуудыг суулгаж, `click` сангийн хувилбарын зөрчлийг тохирох хувилбарыг зааж суулгах замаар арилгасан.

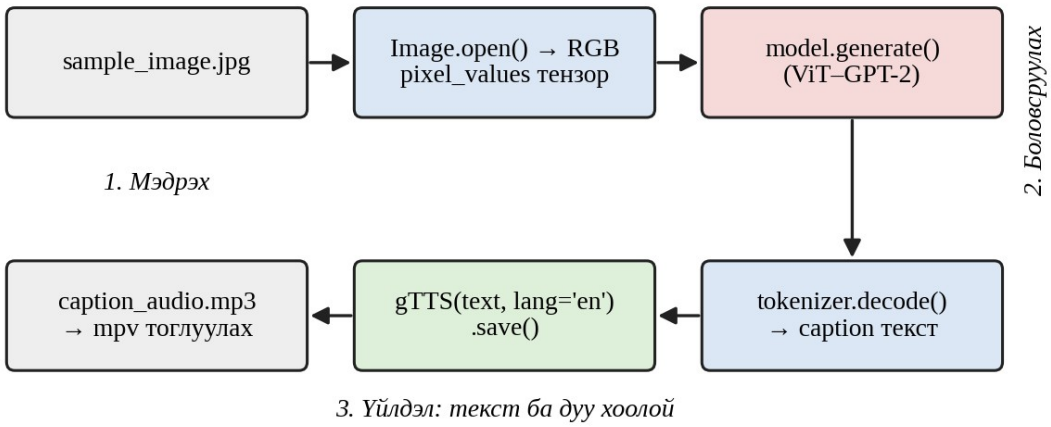
3) Системийн IDLE нь виртуал орчны сангуудыг харахгүй тул `source myenv/bin/activate`-аар орчныг идэвхжүүлээд IDLE-г `python3 -m idlelib &` коммандаар орчин дотроос ажиллуулсан (Зураг 4.2-ын эхний мөрүүд).

3.2. Энгийн болон орчны агент

1) Дүрмийн суурьтай `WeatherAgent` классыг үүсгэж, гараас оруулсан цаг агаарын төлөвт «If–Then» нөхцөлөөр хариу өгөх логикийг бичсэн.
2) `EnvironmentAgent` классыг үүсгэж, оруулсан бохирдлын түвшнийг босго утгатай харьцуулан шийдвэр гаргах логикийг бичсэн.
3) Хоёр агентийг ажиллуулж, цаг агаарт «rainy», бохирдлын түвшинд 75 утга оруулан гаралтыг шалгасан.

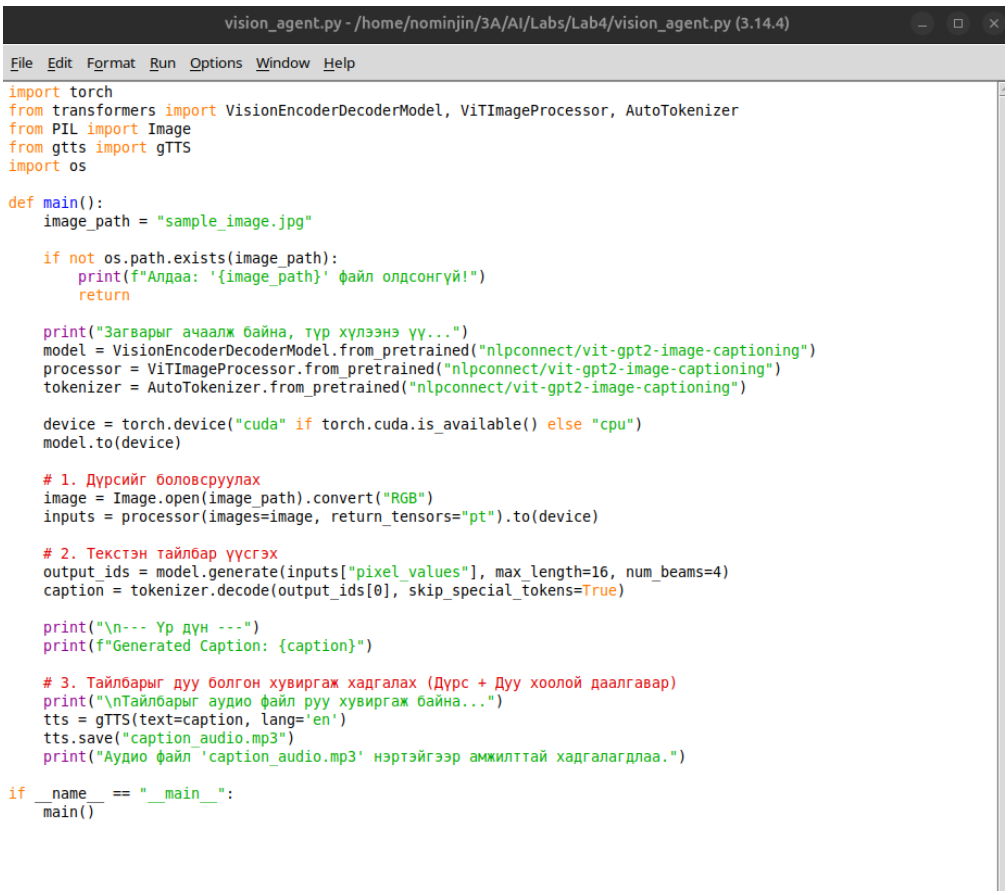
3.3. Multi-modal агент

Multi-modal агентийн ажиллах дарааллыг Зураг 3.1-д үзүүлэв.



Зураг 3.1. Multi-modal агентийн ажиллах дараалал

1) `vision_agent.py` файлд `main()` функц бичиж, эхлээд `os.path.exists()`-ээр зургийн файл байгаа эсэхийг шалгасан (Зураг 3.2).
2) `nlpconnect/vit-gpt2-image-captioning` загварыг Hugging Face Hub-аас `VisionEncoderDecoderModel`-ээр ачаалж, `ViTImageProcessor` болон `AutoTokenizer`-ыг тохируулсан; GPU байвал `cuda`, үгүй бол `cpu` төхөөрөмж сонгосон.
3) `sample_image.jpg` файлыг `Image.open()`-оор уншиж RGB болгон, процессороор `pixel_values` тензорт хувиргасан.
4) `model.generate(..., max_length=16, num_beams=4)` функцээр 4 цацрагтай beam search ашиглан хамгийн ихдээ 16 токентой дараалал үүсгэж, `tokenizer.decode(..., skip_special_tokens=True)`-оор текстэн тайлбар болгосон.
5) Гарсан тайлбарыг gTTS сангаар `caption_audio.mp3` файл болгон хадгалсан.
6) Программыг IDLE-ийн Run → Run Module (F5)-ээр ажиллуулсны дараа Shell цонхонд `import os`, `os.system("mpv caption_audio.mp3")` коммандаар аудиог тоглуулж, буцаасан төлөвийн кодыг (exit status) шалгасан.



Зураг 3.2. `vision_agent.py` программын код (IDLE засварлагч)

4. ХЭМЖИЛТ, ТУРШИЛТЫН ҮР ДҮНГҮҮД

Энэ бүлэгт программуудын гаралтыг боловсруулаагүй хэлбэрээр үзүүлэв. Үр дүнгийн шинжилгээг 5-р бүлэгт хийсэн.

4.1. Энгийн болон орчны агентийн үр дүн

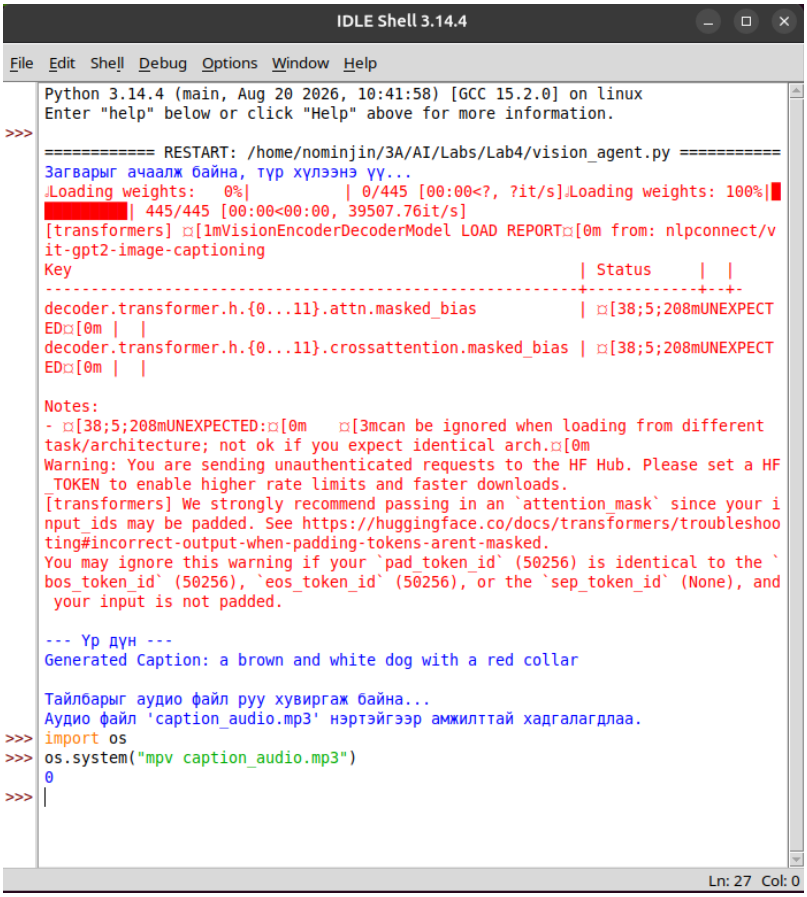
Энгийн агентуудад өгсөн ролт ба гарсан хариуг Хүснэгт 4.1-д үзүүлэв.

Хүснэгт 4.1. Энгийн болон орчны агентийн туршилтын үр дүн

Агент	Ролт	Агентийн гаралт (шийдвэр)
`WeatherAgent`	`rainy`	«Бороонь шүхэр аваарай!»
`EnvironmentAgent`	бохирдлын түвшин 75	«Бохирдол өндөр байна. Агаар шүүгч асаана уу.»

4.2. Multi-modal агентийн үр дүн

`vision_agent.py`-г ажиллуулахад загвар 445 жинг ачаалж, `sample_image.jpg` (нохойн зураг)-д текст тайлбар үүсгэн, аудио файлыг амжилттай хадгалсан (Зураг 4.1). Гаралтын улаан хэсэгт загвар ачаалах үеийн анхааруулгууд (`UNEXPECTED` түлхүүрүүд, HF Hub-ийн нэвтрээгүй хүсэлт, `attention_mask`) харагдаж байгаа бөгөөд тэдгээрийг 5.2-т тайлбарлав.



Зураг 4.1. `vision_agent.py`-ийн гаралт (IDLE Shell)

Shell-ээс `os.system("mpv caption_audio.mp3")` ажиллуулахад 0 буцаасан. Үүний зэрэгцээ IDLE-г эхлүүлсэн терминалд `mpv` тоглуулагч аудиог 1 сувагтай (mono), 24000 Hz, 64 kbps MP3 гэж таньж, PipeWire аудио гаралтаар файлын төгсгөл хүртэл тоглуулсан (Зураг 4.2).



Зураг 4.2. `caption_audio.mp3`-ийг `mpv`-ээр тоглуулсан байдал (терминал)

Үзүүлэлт	Утга
Оролтын зураг	`sample_image.jpg` (нохойн зураг)
Ашигласан загвар	`nlpconnect/vit-gpt2-image-captioning`
Үүссэн тайлбар (caption)	a brown and white dog with a red collar
Үүсгэх тохиргоо	`max_length=16`, `num_beams=4`, төхөөрөмж: `cuda`/`cpu`
Аудио файл	`caption_audio.mp3` (gTTS, `lang='en'`) — амжилттай хадгалагдсан
Аудионы параметр	MP3, 1 суваг (mono), 24000 Hz, 64 kbps
Тоглуулалт (`mpv`)	`os.system()` → 0; «Exiting... (End of file)» — бүрэн тоглуулж дууссан

5. ХЭЛЭЛЦҮҮЛЭГ

Энэ бүлэгт 4-р бүлэгт үзүүлсэн үр дүнг онолын ойлголттой харьцуулан тайлбарлаж, ажиглагдсан хязгаарлалтыг шинжилсэн.

5.1. Дүрмийн агентийн шинжилгээ

`WeatherAgent` ба `EnvironmentAgent` хоёулаа хүлээгдэж буй хариуг гаргасан (Хүснэгт 4.1). Энэ нь 1.3-т тайлбарласан энгийн рефлекс агент нь одоогийн мэдрэмжийг дүрэмтэй тулгаж шууд үйлдэл сонгодог зарчмыг баталж байна. Ийм агент нь тооцооллын зардал бага, хурдан, үр дүн нь урьдчилан таамаглах боломжтой. Гэвч дүрэм нь зөвхөн программист урьдчилан тодорхойлсон нөхцөлийг хамардаг тул таамаглаагүй утга (жишээ нь «foggy» гэх мэт тодорхойлоогүй цаг агаар, сөрөг эсвэл хэт их бохирдлын түвшин) орж ирвэл зохих шийдвэр гаргах боломжгүй. Мөн өмнөх төлөвөө санадаггүй тул бохирдол аажмаар нэмэгдэж байгаа эсэх зэрэг чиг хандлагыг анзаарахгүй [3].

5.2. Multi-modal агентийн шинжилгээ

Загварын үүсгэсэн «a brown and white dog with a red collar» тайлбар нь зургийн гол объект (нохой), түүний өнгө (бор, цагаан) болон нарийн шинж (улаан хүзүүвч)-ийг зөв илэрхийлсэн (Зураг 4.1, 4.2). Энэ нь ViT encoder зургийн пикселүүдийг утга агуулсан онцлог вектор болгож, GPT-2 decoder уг векторуудад cross-attention-ээр хандан контекстэд тохирсон өгүүлбэр үүсгэдэг [4]–[6] зарчмыг харуулж байна. Дүрмийн агентаас ялгаатай нь энэ агентийн «дүрэм» нь их хэмжээний өгөгдлөөс суралцсан жингүүдэд шингэсэн тул урьдчилан тодорхойлоогүй зурган дээр ч тайлбар гаргаж чадна.

Загвар ачаалах үед гарсан анхааруулгууд үр дүнд нөлөөлөөгүй (Зураг 4.1). Decoder-ийн 0–11-р давхаргын `attn.masked_bias` болон `crossattention.masked_bias` түлхүүрүүд `UNEXPECTED` гэж тэмдэглэгдсэн нь хадгалсан жинд байгаа боловч transformers сангийн шинэ хувилбарын GPT-2 бүтцэд шаардлагагүй болсон буфер бөгөөд сан өөрөө «can be ignored» гэж заасан. HF Hub-т токенгүй хандсан анхааруулга нь зөвхөн татах хурдны хязгаартай холбоотой. `attention_mask` дамжуулаагүй анхааруулгын хувьд оролт нь нэг зураг бөгөөд padding хийгдээгүй тул үр дүн зөв гарсан.

Нөгөө талаас загвар нь зөвхөн англи хэлээр сургагдсан тул монгол тайлбар гаргахын тулд нэмэлт орчуулгын алхам шаардлагатай. gTTS нь интернэт холболт шаарддаг [8] тул офлайн

орчинд аудио үүсгэх боломжгүй. `mpv` тоглуулагчийн exit status 0 байсан нь аудио файл зөв үүсч, системийн түвшинд алдаагүй тоглогдсоныг харуулна.

5.3. Туршилтын явцад гарсан асуудал

Туршилтын явцад гарсан техникийн асуудал ба тэдгээрийн шийдлийг Хүснэгт 5.1-д нэгтгэв.

Хүснэгт 5.1. Туршилтын явцад гарсан асуудал ба шийдэл

Асуудал	Шалтгаан	Шийдэл
`externally-managed-environment` алдаа	Ubuntu 24.04 нь системийн Python-д `pip`-ээр шууд сан суулгахыг хориглодог (PEP 668) [10]	`python3-venv`-ээр `myenv` виртуал орчин үүсгэж, сангуудыг тэнд суулгасан [9]
`click` сангийн хувилбарын зөрчил	суулгасан сангуудын шаардсан хувилбарууд хоорондоо тааараагүй	виртуал орчинд тохирох хувилбарыг тусгайлан зааж суулгасан

5.4. Зорилтод хүрсэн байдал

1.1-д тавьсан зорилтууд бүрэн биелсэн. Дүрмийн суурьтай хоёр агент оролтод зөв хариу өгч, энгийн рефлекс агентийн зарчим практикт батлагдсан. Multi-modal агент нь зургийг мэдэрч, англи текст тайлбар үүсгэн, түүнийг `caption_audio.mp3` аудио файл болгож тоглуулснаар дүрс → текст → дуу хоолой гэсэн бүрэн хэлхээ ажилласан.

6. ДҮГНЭЛТ

Лабораторийн ажлаар хиймэл оюуны агентын үндсэн ойлголтуудыг практикт хэрэгжүүлж туршсан. Үр дүнгээс дараах дүгнэлтүүд гарав:

1) Дүрмийн суурьтай `WeatherAgent` нь «rainy» оролтод «Борооны шүхэр аваарай!», `EnvironmentAgent` нь 75 түвшний бохирдолд «Бохирдол өндөр байна. Агаар шүүгч асаана уу.» гэж зөв шийдвэр гаргасан нь энгийн рефлекс агент тодорхой, хязгаарлагдмал нөхцөлд найдвартай ажилладгийг харуулав.
2) ViT–GPT-2 архитектуртай Multi-modal загвар нь `sample_image.jpg`-г «a brown and white dog with a red collar» гэж өнгө, нарийн шинжийн хамт зөв тайлбарласан.
3) gTTS ашиглан тайлбарыг `caption_audio.mp3` болгож, `mpv`-ээр алдаагүй (exit status 0) тоглуулснаар агентийн мэдрэх (perceive) ба үйлдэх (act) чадвар зөвхөн текстээр хязгаарлагдахгүй, дүрс болон дуу хоолойн түвшинд ажиллах боломжтой нь батлагдсан.
4) Ubuntu 24.04 орчинд Python сангуудыг виртуал орчинд суулгах нь системийн хамгаалалт болон хувилбарын зөрчлөөс сэргийлэх зөв арга болох нь тогтоогдов.

Санал, зөвлөмж: дүрмийн агентад тодорхойлоогүй болон буруу утгын (default) дүрэм нэмэх, бохирдлын түүхийг хадгалах төлөвт (model-based) агент болгон өргөжүүлэх, Multi-modal агентийн англи тайлбарыг монгол хэл рүү орчуулж gTTS-д дамжуулах, олон өөр зураг дээр туршиж тайлбарын чанарыг харьцуулахыг зөвлөж байна.

7. АШИГЛАСАН МАТЕРИАЛ

[1] Лабораторийн ажил №4. Агент. «Хиймэл оюуны үндэс», Шинжлэх Ухаан Технологийн Их Сургууль, KOICA e-learning.

[2] Лабораторийн тайлан бичих удирдамж. Шинжлэх Ухаан Технологийн Их Сургууль, Мэдээлэл холбооны технологийн сургууль.

[3] S. Russell, P. Norvig. Artificial Intelligence: A Modern Approach, 4th ed. Pearson, 2020, ch. 2: Intelligent Agents.

[4] A. Dosovitskiy et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR, 2021. https://arxiv.org/abs/2010.11929

[5] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever. Language Models are Unsupervised Multitask Learners. OpenAI, 2019.

[6] nlpconnect. vit-gpt2-image-captioning. Hugging Face Model Hub. https://huggingface.co/nlpconnect/vit-gpt2-image-captioning

[7] Hugging Face. Vision Encoder Decoder Models. Transformers Documentation. https://huggingface.co/docs/transformers/model_doc/vision-encoder-decoder

[8] P. N. Durette. gTTS: Google Text-to-Speech Documentation. https://gtts.readthedocs.io

[9] Python Software Foundation. venv — Creation of virtual environments. https://docs.python.org/3/library/venv.html

[10] PEP 668 – Marking Python base environments as “externally managed”. https://peps.python.org/pep-0668/